



科学研究的人工智能方法学

复旦大学人工智能创新与产业研究院研究员
徐盈辉

未来25年，这125个问题将让科学家“大伤脑筋”

这125个问题，其中涉及生命科学的问题占46%，关系宇宙和地球的问题占16%，与物质科学相关的问题占14%以上，认知科学问题占9%。其余问题分别涉及数学与计算机科学、政治与经济、能源、环境和人口等。



课程简介

本课程旨在为科学研究领域的学者、工程师及相关专业人员提供一个深入了解人工智能（AI）技术在科研中的应用机会。课程从AI技术的基础概念出发，逐步探讨其发展历程，并展示AI在推动科学研究中的多重角色。学员将学习几何深度学习、自监督学习、生成式AI、Physics-Informed AI等关键AI方法，并探索AI在生命科学、材料科学、大气科学和物理等领域的实际应用。

通过本课程，学员将掌握如何利用AI技术解决科研中的复杂问题，从数据处理到实验设计，再到科学模型的构建和优化。课程还将深入探讨AI在科学领域的挑战，包括数据质量、模型解释性等，并对AI在未来科研中的前景进行展望。最终，学员将具备独立使用AI技术辅助科学研究的能力，为其科研创新提供全新的技术工具和思维框架。



课程特点

1. 结合理论讲解与实际案例分析，帮助学员深入理解AI的科研应用。
2. 涵盖几何深度学习、生成式AI、Physics-Informed AI等最新的AI技术。
3. 针对生命科学、材料科学、大气科学和物理等学科领域的应用进行详细解析。
4. 重点讨论AI在科研中的实际挑战和未来发展趋势。



课程大纲

课程大纲

• 课程简介与科学研究中的AI概述		10.11
○ 课程介绍		10.25
○ 人工智能技术的发展与进化		
○ 人工智能时代的科学研究-1	8个学时	11.01
○ 人工智能时代的科学研究-2		11.08
• 科学研究的人工智能方法介绍		
○ 几何深度学习		11.15
○ 自监督学习/大模型	16个学时	11.22
○ 生成式AI		
○ Physics informed AI		11.29
• AI在科学领域的应用介绍		12.6
○ ai + 生命科学	16个学时	
○ ai + 材料科学		12.13
○ ai + 大气科学		12.20
○ <u>ai + 物理</u>		12.27
• AI在科学领域的挑战和未来展望	12个学时	
○ ai在科学领域的挑战		01.03
○ ai在科学领域的展望		01.10



课程考核

方案1: 课程项目为主, 会设立4到5个科学+ai领域的project, 学员组队参加, 提交课程实验报告和结果, 鼓励基于课程项目发表学术论文

方案2:

学员根据自己从事的 AI+science 的研究做成研究报告

一场正在发生的科研范式变革



《 Science 》刊登麻省理工
AI药物逆合成设计论文，AI合
成了**15个**药物分子

2019.3

利物浦大学使用AI发现**4种**可
传导锂的新固态材料，可提
供更长续航能力


2021.5

Deepmind宣布开放包括多
个动物、植物的**2亿**个蛋白质
结构的预测结果

2022.7



思维方法



船长观察到前面有座冰山

归纳法

从**问题**出发找到最终原因

演绎法

从**原理**出发找到解决方法



如何思考



The man who grasps principles can successfully select his own methods. The man who tries methods, ignoring principles, is sure to have trouble.
~ Ralph Waldo Emerson

科学的本质在于探究事物背后的基本原理

第一性原理（公理、公设 和/或 假设）+ 演绎推理 = 思想或学科体系

笛卡尔方法论

我思故我在

绝不接受任何东西为真

分成尽可能多的小块

从最简单的和最容易认识的东西着手，以逐步认识更复杂的

尽可能详细、尽可能全面地考察所有东西

归纳法

任何归纳法都有时空边界

独立可重复性

历史 = 未来

人类很多错误都是源于把边界之内的规律不恰当的推到了边界之外

归纳法的隐含假设：连续性假设

求存不求真的阿喀琉斯之踵

演绎法

通过一件事物推导出另一件事物，中间存在一个「必然的导出」

三段论：大前提、小前提和结论

大道至简

逆推法追根溯源，从眼前要解决的问题开始，分析产生这个问题的原因，再分析产生原因的原因

第一性原理

第一性原理是基本的命题和假设，不能被省略和删除，也不能被违反

宇宙的第一性原理
看透事物本质

本体论
简一律
动力因

Dynamics，发展变化的，实践出真知




ai for science/science for ai

Generative models	Statistical physics
Negative log-likelihood	Energy function
Score function	Force
Latent variables	Collective variables/coarse graining/renormalization group
Partition function	Free energy calculation
Sample diversity	Enhanced sampling

从统计、量子、
流体等物理学领
域为生成模型提
供新的洞见。

现代生成模型
的强大能力为
物理学服务



生成模型源于统计物理学中的玻尔兹曼分布，用于模拟概率分布，通常与蒙特卡洛方法、Ising模型等物理概念关联

结合了变分推断的思想，应用于高维数据的生成，与物理学中的“变分平均场 (Variational Mean Field)”技术相关

基于物理中的非平衡热力学理论，模拟数据的逐渐演变并进行生成任务

基于量子物理学，特别是Born规则，利用量子线路和张量网络等工具来进行数据生成

基于流体力学中的最优传输理论，通过流动与匹配来实现生成任务




人工智能技术的发展与进化



人工智能的基本定义

"机器是否可以思考?"

—— Alan Turing (图灵测试的提出者)



人工智能 (Artificial Intelligence, AI) 通常被定义为使计算机或机器能够执行通常需要人类智慧任务的技术。这些任务包括理解自然语言、视觉识别、决策制定、和人类互动等。AI的核心目标是创建可以自主地、有效地解决问题的系统。

AI的多样性

按技术分类

机器学习 (ML)
深度学习
符号主义
进化算法
...

按应用领域分类

自然语言处理 (NLP)
计算机视觉
机器人技术
专家系统

按学习方式分


监督学习
无监督学习
强化学习

按功能分

感知AI
认知AI
生成AI
决策AI



人工智能的演化






AI 蓬勃发展期的重大事件

- 从机器学习向深度学习演变
- 从专家系统 + 机器学习 向 基于深度学习的生成式AI转变
 - From Eliza to ChatGPT
 - From Watson to GPT4
 - From Deep Blue to AlphaGo
- 从完全信息博弈到不完全信息博弈
 - From AlphaGo to Libratus
- 数据 + 算力 + 算法 推动人工智能变革



Examples on Machine learning

Supervised ML = Function Approximation



$$f: x \rightarrow y$$

Machine Translation

X : 机器学习及其深层于结构化

sentence of language 1

Y : "Machine learning and
having it deep and structured"

sentence of language 2

Speech Recognition

X : 
(speech)

Y : 感谢大家来听报告

transcription

Chat-bot


X : "How are you?"
(what a user says)

user prompt

Y : "I'm fine."
(response of machine)

response of machine

image to image



Text to Image

X : "this white and yellow flower
have thin white petals and a
round yellow stamen"

Y :




Deep Learning in one slides

Many kinds of network structures:

- Fully connected feedforward network
- Convolutional neural network (CNN)
- Recurrent neural network (RNN)

Different networks can take different kinds of input/output.




How to find
the function?

Given the example inputs/outputs as
training data: $\{(x_1, y_1), (x_2, y_2), \dots, (x_{1000}, y_{1000})\}$



重大事件 @ 深度学习时代

Timeline of Key Events in Deep Learning



stable
diffusion



Fred Bertsch



Erich Elsen



Anmol Gulati



David Luan



Maxwell Nye



Augustus Odena



Niki Parmar



Kelsey Schroeder



Ashish Vaswani

Transformer

RNN/LSTM



From Eliza to ChatGPT

模拟人类心理治疗师（Rogerian 理论）

```
=====
EEEEEEEE L      IIIIII ZZZZZZZ      AAA
E         L      I      Z      A      A
E         L      I      Z      A      A
EEEEEE   L      I      Z      A      A
E         L      I      Z      A      A
EEEEEEEE LLLLLLLL IIIIII ZZZZZZ      A      A
=====
ELIZA > (PLEASE TYPE IN ALL CAPS) WHAT'S YOUR NAME DEAR ?
AMIT
ELIZA > HI, I'M ELIZA. WHAT DO YOU WANT TO TALK ABOUT ?
AMIT > CAN I TALK ABOUT MY PROBLEM ?
ELIZA > SURE... !
AMIT > DUE TO ON GOING EXAMS IN COLLEGE, I HAVE A LOT OF STRESS.
ELIZA > PLEASE RELAX A LITTLE. SLEEP WELL.
AMIT > THANKS FOR YOUR ADVICE.
ELIZA > NO MENTION.
AMIT > BYE
ELIZA > BYE AND KEEP IN TOUCH...
=====
```



特点/程序	ELIZA	ChatGPT
发展时期	1960年代	21世纪 10 年代后半期
设计目的	模拟心理治疗师的对话	广泛的对话任务
技术实现	基于规则的模式匹配	基于 Transformer 的深度学习模型
响应质量	简单、机械、可预测	连贯、有深度、多样化
灵活性	手动编写模式匹配规则	可通过训练数据进行调整或扩展
应用领域	研究工具、演示	客服、创意写作、技术支持等多种应用

情感与共鸣： 心理咨询不仅仅是给出建议，还需要有深度的情感共鸣和理解。这是大语言模型的一个挑战。可能需要开发新的模型结构或技术来更好地捕捉和理解人类的情感。

界定边界： 即使大语言模型具备了一定的心理咨询能力，也需要明确其界限，确保用户知道何时需要寻找真正的专业帮助。

From Watson to GPT4



IBM Watson 在医疗健康领域的滑铁卢:

1. 数据复杂性
2. 隐私和合规
3. 新医疗知识的适配
4. 系统集成的复杂度
5. 医疗专家的接受度
6. 技术的局限性

	IBM Weston	gpt4
技术路线		
核心目标 数据训练 模型结构	问答系统 知识图谱, 结构化数据 多模型组合	生成连贯性文本 巨大的文本数据集 Transformer (GPT)
系统差异		
应用范围 交互方式	特定问题 (如医疗) 查询系统	通用文本生成 对话式交互
pros	领域专家 知识图谱 可定制化	通用性 易于交互 大规模训练
cons	灵活定制 部署成本	模糊性 偏见问题 需要大量计算资源

仍然面临的挑战:

1. 信息的时效性
2. 可解释性
3. 隐私和合规



From Deep Blue to AlphaGo




LEE
SEDOL
IN GAME 5
AGAINST
ALPHAGO



特点/项目	Deep Blue	AlphaGo
开发公司	IBM	DeepMind
目标游戏	国际象棋 - 状态空间： $10^{43} \sim 10^{50}$ - 游戏树复杂度： 10^{123}	围棋 - 状态空间： 10^{170} - 游戏树复杂度： 10^{360}
核心技术	min-max搜索 & alpha-beta剪枝	深度神经网络 & 蒙特卡洛树搜索
硬件	定制的超级计算机	通用图形处理单元 (GPUs)
学习能力	无	有 (自对弈和增强学习)
依赖人的知识	是	初始阶段是，但后续主要自主学习
通用性	不具有	较高(已被运用到其他任务和游戏)
数据来源	人类专家知识、开局、残局数据库	人类比赛数据，然后通过自对弈生成数据
算法和方法	- 传统的min-max搜索 - alpha-beta剪枝 - 巨大的开局和残局数据库 - 并行硬件计算	- 使用深度神经网络评估棋盘和选择着法 - 蒙特卡洛树搜索 (MCTS) 探索着法 - 自对弈及增强学习进行训练

From AlphaGo to Libratus




特点/方法	完全信息博弈	不完全信息博弈
定义	所有游戏状态信息对所有玩家都可见	玩家并不完全知道游戏的当前状态
示例	国际象棋、围棋	扑克
信息表示	精确的游戏状态表示	考虑不确定性和概率
策略构建	策略较为确定和直接	考虑对手的潜在策略和隐藏信息
计算复杂性	相对较低	通常更高
经典算法	Minimax、Alpha-beta 剪枝、MCTS	期望最大化、贝叶斯推断、博弈树搜索
近期技术	蒙特卡洛树搜索与深度学习结合	策略梯度方法与深度学习结合




from model-centric to data-centric

ai 范式改变的元年
2023

判别式人工智能时代



生成式人工智能时代



更关注于做Model

machine in the human loop

人类生产的大量数据（语言，
图片，视频）由机器采集

更关注于做Data

human in the machine loop

基于人类生产的大量数据构造生成式大模型，实现根据
人类自然语言交互完成信息的生产，分析，解读与反馈



历史上2次信息科学的革命



大型语言模型综述全新出炉：从T5到GPT-4最全盘点，国内20余位研究者联合撰写

自20世纪50年代图灵测试提出以来，人们始终在探索机器处理语言智能的能力。语言本质上是一个错综复杂的人类表达系统，受到语法规则的约束。因此，开发能够理解和精通语言的强大AI算法面临着巨大挑战。过去二十年，语言建模方法被广泛应用于语言理解和生成，包括统计语言模型和神经网络语言模型。

近些年，研究人员通过在大规模语料库上预训练Transformer模型产生了预训练语言模型（PLMs），并在解决各类NLP任务上展现出了强大的能力。并且研究人员发现模型缩放可以带来性能提升，因此他们通过将模型规模增大进一步研究缩放的效果。有趣的是，当参数规模超过一定水平时，这个更大的语言模型实现了显著的性能提升，并出现了小模型中不存在的能力，比如上下文学习。为了区别于PLM，这类模型被称为大型语言模型（LLMs）。

从2019年的谷歌T5到OpenAI GPT系列，参数量爆炸的大模型不断涌现。可以说，LLMs的研究在学界和业界都得到了很大的推进，尤其去年11月底对话大模型ChatGPT的出现更是引起了社会各界的广泛关注。LLMs的技术进展对整个AI社区产




I am feeling lucky

信息消费



machine generation
与 human feedback
更加直接

AI 第一次大规模找到并运用隐藏在自然语言文本中的监督指令





GPT = 知识（融合+传承+应用+探索）



大模型 + 大数据 = 神奇的力量
(能力的涌现)

GPT3 : 1750亿

1.4T token

人脑大约有860
亿神经元

相当于2000w本书籍

相当于2倍的人
脑神经元体量

以每秒读5个token的速度，
你需要大约12,675
年才能读完2T tokens

人 = 信息 + 任务 + 领域模型

GPT = 信息系统 + 模型系统 + 行动系统

GPT = 通识模型 + 行业适配 + 翻译一切



深度学习研究范式演变

rompting + Sequence-to-sequence Pre-training
<https://www.youtube.com/watch?v=TE6urdkTR4I>

Paradigm	Engineering	Task Relation
a. Fully Supervised Learning (Non-Neural Network)	Features (e.g. word identity, part-of-speech, sentence length)	
b. Fully Supervised Learning (Neural Network)	Architecture (e.g. convolutional, recurrent, self-attentional)	
c. Pre-train, Fine-tune	Objective (e.g. masked language modeling, next sentence prediction)	
d. Pre-train, Prompt, Predict	Prompt (e.g. cloze, prefix)	

objective engineering

- **Paradigm:** Pre-train, Fine-tune
- **Time Period:** 2017-Now
- **Characteristics:**
 - Pre-trained LMs (PLMs) used as initialization of full model - both shallow and deep features
 - Less work on architecture design, but engineer objective functions
- **Typical Work:**
 - BERT → Fine Tuning

prompt engineering

- **Paradigm:** Pre-train, Prompt, Predict
- **Date:** 2019-Now
- **Characteristic:**
 - NLP tasks are modeled entirely by relying on LMs
 - The tasks of shallow and deep feature extraction, and prediction of the data are all given to the LM
 - Engineering of prompts is required
- **Representative Work:**
 - GPT3

Feature engineering

- **Paradigm:** Fully Supervised Learning (Non-neural Network)
- **Time Period:** Most popular through 2015
- **Characteristics:**
 - Non-neural machine learning models mainly used
 - Require manually defined feature extraction
- **Representative Work:**
 - Manual features -> linear or kernelized support vector machine (SVM)
 - Manual features -> conditional random fields (CRF)

Architecture engineering

- **Paradigm:** Fully Supervised Learning (Neural Networks)
- **Time Period:** About 2013-2018
- **Characteristics:**
 - Rely on neural networks
 - Do not need to manually define features, but should modify the network structure (e.g.: LSTM v.s CNN)
 - Sometimes used pre-training of LMs, but often only for shallow features such as embeddings



文生图 – stable diffusion

The world's largest black forest cake, the size of a building, surrounded by trees of the black forest




Cinematic still photo of a couple. emotional, harmonious, vignette, 4k epic detailed, shot on kodak, 35mm photo, sharp focus, high budget, cinemascope, moody, epic, gorgeous, film grain, grain



Write this poem with cursive text on a background that fits the words:
Roses are red Violets are blue,
Sugar is sweet And so are you.




能够根据人类指令生成长达一分钟视频的模型，同时保持较高的视觉质量和引人注目的视觉连贯性，从第一帧到最后一帧都具有渐进感和视觉连贯性






数据驱动的人工智能全景图 @ 2023 ~

知错就改
分而治之
众志成城
层层堆叠




机器学习模型对于数据的“饥渴”


确定性
传感设备采集的客观反馈信号



需要大量有正确结果的标注数据



全样本空间的理解，数据内在结构的挖掘



Reinforcement Learning (cherry)

- The machine predicts a scalar reward given once in a while.
- **A few bits for some samples**

Supervised Learning (icing)

- The machine predicts a category or a few numbers for each input
- **10→10,000 bits per sample**

Unsupervised Learning (cake)


- The machine predicts any part of its input for any observed part.
- Predicts future frames in videos
- **Millions of bits per sample**



NIPS16: Yann Lecun's chocolate cake

数据智能时代的挑战

需要大量的训练数据





在人工智能时代的科学研究




大模型技术带来新一轮AI创新

AI4S大模型体系，服务广泛、多种类科学研究需求

大语言模型



OpenAI's New
ChatGPT



AI4S大模型




运筹学




经济学

实体关系/行为
数据


...



材料科学




生命科学




大气科学


科学领域设备
观测/实验数据



分子动力学



流体力学



空气动力学

模拟仿真数据


科学
大数据



科研范式转变：物理/实验驱动 → 数据沉浸式科学驱动

科学仪器的飞速发展
计算机模拟软件的能力提升

浮点运算速度 (TFLOPS)



数据

科学可测量大数据的爆发式增长

- 基因组学「数百/数千PB」
 - 全球范围内的生物序列数据已经超过数百万个物种的基因组数据，总数据量已达数百至数千PB
- 蛋白质结构
 - 蛋白质数据银行 (PDB) 已收录了超过18万+个蛋白质和核酸的三维结构信息，数据量达到数TB
- 天文学
 - 天文学领域的观测数据规模已经达到数PB
- 地球观测
 - 欧洲空间局的哥白尼观测计划每天产生约10TB的地球观测数据，预计未来几年数据规模将达到数PB
- 粒子物理
 - 在粒子物理领域，大型强子对撞机 (LHC) 每年产生约30PB的原始数据，加上模拟数据和分析数据，总数据量将达到数百PB
- 医学影像
 - 全球范围内的医学影像数据已经达到数百PB

算力

算力的持续提升

算法

人工智能进入生成式时代


chatgpt @ NLP
stable diffusion @ CV

科学探索中智能的本质

宏观世界
可观测/可度量



微观世界
不可观测/难度量




科学的定义

确实遵守其基本原则且立足于客观事实的系统性研究领域，以可被检验的假说与预测为形式，进行知识的建构与组织工作

“**Computational Science** can **analyze past events** and **look into the Data future**. It can explore the effects of thousands of scenarios for or in lieu of actual experiment and be used to study events beyond the reach of expanding the boundaries of experimental science”
—Tinsley Oden, 2013




从微观到宏观



认识宇宙

时间尺度

y
:
h
s
ms
us
ns
ps
fs



时间尺度	单位	物质现象
秒级及以上	秒 分钟 小时 天	化学反应时间，生物过程时间 代谢过程 光合作用 昼夜影响
毫秒到微秒	毫秒 微秒	神经信号传递 分子碰撞，快速化学反应
纳秒到皮秒	纳秒 皮秒	原子间相互作用，蛋白质折叠 分子的振动过程，化学键的形成和断裂时间
飞秒到阿秒	飞秒 阿秒	分子内部电子重排 电子跃迁过程，原子核外电子的动态行为





空间尺度	单位	物质现象
米及以上	毫米 厘米 米 千米	沙粒/昆虫的翅膀厚度 小型生物/器官 人体高度 山脉/河流/地质断层
微米到纳米	微米 纳米	细菌/细胞大小 病毒/蛋白/DNA双螺旋直径
皮米到飞米	皮米 Å 飞米	分子的键长 原子/分子尺度长度 原子核大小
天文尺度	秒差距 光年 天文单位	星系距离 恒星之间距离 地球到太阳的距离

质量单位：吨/千克/克/毫克/微克/纳克/皮克/道尔顿 (Da)


空间尺度



科学研究的发展范式




洛伦茨方程
Naier-Stokes 方程
Etc..



Jim Gray, Turing Award 1998 (1944-2007)
Honoured as father of **The 4th Paradigm**
Image source: Wikipedia





Weather forecasting



Battery design optimization



Magnetic control of nuclear fusion reactors



Planning chemical synthesis pathway



Rare event selection in particle collisions



Language modelling for biomedical sequences



High-throughput virtual screening



Neural solvers of differential equations



Hydropower station location planning



Synthetic electronic health record generation



Navigation in the hypothesis space



Super-resolution 3D live-cell imaging



Symbolic regression



AI4S工作数量井喷，AI已成为重要的科研手段

占比34.5%

193,500

近3年来科学论文总数量

66,800


其中采用了AI的论文数量



依据google学术数据统计，以材料科学/生命科学/能源科学三个学科为例，近3年使用AI手段开展科研的比例超过34.5%；3年内使用AI的论文数量增长率超3倍

注：以上数据均来源于公开数据

AI for science 的重要任务





AI + scientific literature & evidence discovery

The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery

Chris Lu^{1,2,*}, Cong Lu^{3,4,*}, Robert Tjarko Lange^{1,*}, Jakob Foerster^{2,†}, Jeff Clune^{3,4,5,†} and David Ha^{1,†}

^{*}Equal Contribution, ¹Sakana AI, ²FLAIR, University of Oxford, ³University of British Columbia, ⁴Vector Institute, ⁵Canada CIFAR AI Chair, [†]Equal Advising

首个端到端自动化科学发现框架



Idea Generation

自动生成研究想法与实验

低成本的科学论文生成

自动化审稿系统

跨多个机器学习领域的应用



AI + scientific literature & evidence discovery

<https://future.com/how-to-build-gpt-3-for-science/>

How to Build a GPT-3 for Science (scientific literature and data)

G_{enerative} **P**_{retrained} **T**_{ransformer}

$\text{text} \sim p(\text{text} | \text{prompt})$

Josh Nicholson

Posted August 18, 2022

You may ask (prompts):

Galactica, ChemGPT, MaterBERT,
ChemCrow, MatChat...

“Tell me why this hypothesis is wrong”

“Tell me why my treatment idea won’t work”

“Generate a new treatment idea”

“What evidence is there to support social policy X?”

“Who has published the most reliable research in this field?”

“Write me a scientific paper based on my data”

AI + 理解 @ 蛋白质结构预测





从蛋白质的氨基酸序列中准确预测其三维结构




2020 DeepMind推出**AlphaFold2**，蛋白质结构预测**误差低于1个原子**的大小，达到冷冻电镜的观测水平

2022 Meta推出**ESMFold**，语言模型消除显式同源序列MSA依赖，**速度提升一个量级**



AlphaFold2, DeepMind, 2021




ESMFold, Meta, 2021



AI + 理解 @ 大气科学

建设人工智能和数值模式双驱动的气象大模型，**跨周期、跨尺度**地理解海量多模态气象观测数据，对气候现象以及气候现象的产业影响进行**高精度、高密度**的预报，促进物流、能源和金融产业发展。

AI+气象大模型



多个领域产业应用



物流



金融



新能源



AI + 理解 @ 计算生物学（多组学）

建设生命科学大模型，**多尺度、多时间、多维度** 解译基因调控及生物学通路、药物与生命体互作用等生命科学重要问题，提升关键生命科学应用技术，促进健康管理和制药产业发展


医药健康**产业应用**




临床诊疗



健康管理



AI+生命科学大模型
理解生命科学重要机理




表型组学	生理年龄 - 时钟年龄
甲基化	3.01
免疫	5.69
代谢	5.61

Horvath DNA 甲基化生理年龄 - 时钟年龄 = 3.6 岁


要解决科学问题： 如何有效地在广阔的化学空间中搜索以找到具有期望性质的无机材料

接近38.4万种材料，分别来自OQMD、Materials Project和ICSD三个不同的无机材料数据库

材料被表示为稀疏矩阵形式，每种元素的原子数被编码



生成假设的、化学上有效的新材料样本。采用Wasserstein GAN框架以提高模型性能，GAN的生成器负责生成新的材料样本，判别器则负责区分这些生成样本与真实样本之间的差异



MatGAN模型在生成200万个样本中，达到了92.53%的新颖性，84.5%的样本是化学有效的（满足电中性和电负性平衡）。

与穷举枚举方法相比，该模型在采样效率上提高了77倍

Generative adversarial networks (GAN) based efficient sampling of chemical space for inverse design of inorganic materials




AI + 设计 @ 科学发现和人工智能互相促进的良性循环



扩散过程
(**热力学**)




启发



扩散模型
(**掀起AIGC热潮**)




赋能




构象生成


(**赋能化学研究与药物设计**)



分子生成



启发




“泊松流”
生成模型

PFGM

提速10-20倍


AI + 仿真 @ 分子动力学

基于量化计算软件的模拟数据实现「数据+物理」驱动的分
子动力学计算




基于高斯量化计算软件构造训练数据

AI Force Field Accuracy



Force field-QM energy difference distribution of 15000 torsional potential energy surfaces

FEP Accuracy



AI FEP R² Accuracy: BACE, CDK2, JNK1, MCL1, P38, PTP1B, Tyk2, Thrombin, 8 protein systems, 199 ligands



AI + 物理仿真 @ 微观物理模型与AI结合

只考虑物质科学领域特定的横向（如合金、高分子、化工等）、纵向（如制备、结构、性质等）子领域，很难形成统一的基础大模型

■ 分子一维、二维属性

■ 材料制备和反应条件预测

■ 晶体材料三维结构的生成

■ 特定物质的性质预测

微观尺度物理理论的AI模型

从微观物理理论出发，可以抓住复杂的物质科学领域的共性问题，是开发基础共性物质科学大模型的可行途径

AI分子势 (potential)

解决能量的问题

势函数物理约束

大规模QM计算数据

量子力学

AI采样 (sampling)

解决动态结构的问题

stable diffusion + transformer

大规模MD计算轨迹数据

分子动力学

(化学) 分子大模型

解决性质预测的问题


大模型技术

MC预训练任务


统计热力学

AI + 大规模加速跨尺度难题求解


- 预测气泡体积随着液体压力变化而变化在水下螺旋桨推进等领域具有重要价值
- 气泡问题横跨五六个长度尺度涉及连续介质模型和分子模型，跨尺度模型通信是痛点
- 人工智能模型同时学习多个尺度的知识，成为一个统一的代理模型，简化工程应用



裂纹的发生和扩散




血细胞的阻塞和对供血的影响




大幅加速流体跨尺度求解，比传统物理模型求解快1000倍以上


科学问题的特色：数据贵；有物理知识




思路：在学习过程中，通过物理知识和已知数据点共同约束学习过程






应用1：通过医学影像结合流体知识，推测血管瘤内的压力



应用2：通过少数测量点和流体知识，优化汽车风洞设计的效率和准确度





相比物理仿真方法

在湍流的直接数值仿真（Direct Numerical Simulation, DNS）和大涡仿真（Large Eddy Simulation, LES）方面，数据驱动的AI方法在每个空间维度的分辨率是前者的8-10倍，实现了40-80倍的计算加速

使用 forced turbulence 来创造和控制湍流场，产生训练数据，从而用深度学习来拟合湍流过程中复杂的多尺度和多物理过程相互作用的规律。



AI + 药物发现 (ADME/T 预测)

分子数据库

第一步:
利用基于第一性原理的方法
(如DFT)进行计算得到分子数据库(依赖于构象的物理性质):

1. 分子的3D 构象
2. 电荷分布
3. 能量
4. 偶极矩
5. ...

第二步:
通过批量试验获得这些分子最基本的物化性质:


1. logP
2. logD
3. logS
4. pKa

物化性质

logP
logS
pKa
logD
...




物化性质预测模型

运用分子数据库中的分子数据作为训练数据,将物理规则和AI大模型结合,构建可以快速准确预测物化性质的model.



药化性质预测模型

结合3D分子构象和预测(实验)物化属性数据构建AI分子pretrained model, 在少量(实验)药化性质数据上进行 zero/few-shot learning, 得到药化性质预测模型



AI + 高度复杂动态系统控制

★ AI（通过深度强化学习）如何管理高度复杂且动态的系统 ★

DeepMind used deep reinforcement learning (RL) for controlling [1] fusion plasma, and control novel plasma shapes.


等离子体控制中的强化学习：

控制策略：

在实时状态下调整等离子体的形状。控制策略将系统的观察结果（例如等离子体状态）映射到相应的控制动作（如线圈电流的调节），以达到特定的目标

VS


传统系统使用前馈控制机制和手动调整来实现相同的等离子体形状控制目标。



[1] Degraeve, Jonas, et al. "Magnetic control of tokamak plasmas through deep reinforcement learning." *Nature* 602.7897 (2022): 414-419.

极向场线圈 线圈用于控制磁场，从而影响等离子体的形状
 等离子体形状控制 通过调节线圈电流来将等离子体调整为适合核聚变的特定形状

混合整数规划 @ 运筹优化



DeepMind、谷歌研究者基于神经网络算法改进混合整数编程求解器

交通运输业



生产制造业



能源行业




电信行业



How AI could help science ?

1. 量子力学中的原理
2. 经典力学的原理
3. 化学反应经验规律



$$P(\text{hypothesis}|\text{data}) = \frac{P(\text{hypothesis})P(\text{data}|\text{hypothesis})}{\sum_{\mathbf{h}} P(\mathbf{h})P(\text{data}|\mathbf{h})}$$

