



科学研究的人工智能方法学

复旦大学人工智能创新与产业研究院研究员
徐盈辉

未来25年，这125个问题将让科学家“大伤脑筋”

这125个问题，其中涉及生命科学的问题占46%，关系宇宙和地球的问题占16%，与物质科学相关的问题占14%以上，认知科学问题占9%。其余问题分别涉及数学与计算机科学、政治与经济、能源、环境和人口等。

一场正在发生的科研范式变革



《 Science 》刊登麻省理工
AI药物逆合成设计论文，AI合
成了**15个**药物分子

2019.3

利物浦大学使用AI发现**4种**可
传导锂的新固态材料，可提
供更长续航能力


2021.5

Deepmind宣布开放包括多
个动物、植物的**2亿**个蛋白质
结构的预测结果

2022.7

数据智能时代的挑战


需要大量的训练数据



How AI could help science ?

贝叶斯公式中的数据与理论的差异

1. 量子力学中的原理
2. 经典力学的原理
3. 化学反应经验规律



$$P(\text{hypothesis} | \text{data}) = \frac{P(\text{hypothesis}) P(\text{data} | \text{hypothesis})}{\sum_{\mathbf{h}} P(\mathbf{h}) P(\text{data} | \mathbf{h})}$$



scientific foundation Model

General-purpose technologies that can support a diverse range of use cases

- 1 数据驱动 多尺度/高维度/多模态的时空数据融合能力
- 2 基于深度神经网络 “可重用的基础设施”，而不是定制/一次性的解决方案
- 3 生成式AI的训练模式
 1. 将基础模型适配于特定的用例或直接使用它的成本要低得多
 2. 少样本/零样本推理能力
 3. 长时序依赖建模能力
 4. 支持开放式问题解答与发现
- 4 可解释性/物理与化学先验知识融入
 1. 知识注入与结构化建模
- 5 可靠的误差估计与不确定性量化能力
大规模知识整合与持续学习能力




Why scientific foundation Model ?

》提升探索能力 learning new science (explore)
激发创新和发现未知
explore unknown scientific space

》加速和加深理解能力 capture expensive science (accelerate)
a). 弥合理论与数据的差距 “surrogate” modeling
b). 知识集成与跨领域学习. Fast/accurate
c). Automatic differentiation for optimization

》复杂系统构建能力 capturing multi-physics interactions (complex system/multi-agent)
> 差异建模 (discrepancy modeling)
> 复杂的数据分析和模拟过程变得更自动化

》动态性/时效性 update model with new data (dynamics)





科学研究的突破需要有组织科研



我们如何来审视“大”数据



每个研究者或技术人员都只看到了数据或系统的一部分，无法理解整体的复杂性。

各自根据所看到的部分作出自己的解释和行动，但却忽略了数据的整体性和完整性。

科学研究数据

• 实验数据 (Experimental Data):



- **定义**: 实验数据是通过控制条件的实验而获得的结果。研究人员在实验室中进行一系列控制性实验, 记录下不同变量下的测量值。这些数据通常可以在重复实验中被验证和复现。
- **示例**: 化学反应中测量到的温度变化、药物试验中不同剂量对实验对象的生理反应等。

• 观测数据 (Observational Data):

- **定义**: 观测数据是通过对自然现象的观察和测量而获得的。这类数据不涉及研究人员对变量的直接控制, 而是对已有现象进行记录和分析。它适用于难以进行控制实验的领域。
- **示例**: 天文望远镜收集的宇宙星系光谱数据、地震仪记录的地震数据、生态学研究中对动物行为的观察。

• 模拟和计算数据 (Simulation and Computational Data)

- **定义**: 模拟和计算数据是通过计算机模拟和数值计算生成的结果, 用于研究复杂系统的行为或预测未来的趋势。这些数据是通过模拟物理、化学、生物等过程来获取的, 特别是在实验无法直接进行时。
- **示例**: 气象模型产生的气候预测数据、流体动力学模拟中的涡流数据、分子动力学模拟中原子行为的计算结果。





维度诅咒 @ 科学研究数据

计算复杂性增加

在高维空间中进行距离计算或矩阵操作等任务时，这会导致计算资源的消耗急剧增加。

数据稀疏性

高维空间中的数据点变得非常稀疏

距离度量的难度

在高维空间中，所有数据点之间的距离趋于相等，导致传统的基于距离的算法（如k近邻算法）的效果变差

维度增加对模型的影响

在高维数据中，机器学习模型容易出现过拟合，因为每个维度都可能增加噪声和无关特征，导致模型复杂度增加

可视化和理解的困难

高维数据难以通过图形化方式直接可视化，这使得数据的理解和特征工程变得更加复杂

数据量的要求增加

为了有效地覆盖高维空间并减少稀疏性问题，需要指数级增加数据量，这通常是不现实的，尤其是在科学研究中，数据收集的成本很高。



科学研究数据的复杂性

数据复杂性高

多尺度/高维度/多模态
动态变化/时间依赖

Coordinates matters
Confounding factors

数据量庞大，有效数据少

信噪比低/数据质量差
缺失值
暴露偏差问题

特征提取和数据标注困难



生命科学领域数据

多尺度 (Multi-Scale)

多尺度数据指生命系统的不同层次，从分子水平到整个生物体，甚至到种群和生态系统层次，所有这些层次的数据都可能需要综合考虑。具体包括：

•空间尺度：

- **分子尺度**：例如基因、蛋白质、代谢物等分子生物数据，反映生物体内部的化学和分子活动。
- **细胞尺度**：包括单细胞的基因表达、信号传导网络、细胞分裂等，是生命科学中对功能单元的研究。
- **组织和器官尺度**：例如组织显微成像数据，反映生物体器官或组织的结构和功能活动。
- **个体和生态尺度**：从个体生物的生理特征数据到种群、生态系统的数据，例如行为数据或生态网络。

•时间尺度：

- **瞬时变化**：例如神经细胞中的电信号活动，这些数据在毫秒级时间尺度上变化。
- **长期变化**：包括个体生长过程、代谢适应，以及种群进化过程，可能跨越多个时间尺度，从小时、天到数月甚至数年。

高维度 (High-Dimensionality)

高维度数据在生命科学领域指数据中包含大量特征或变量，通常涉及复杂的生物系统：

• **特征数量远多于样本数量**：生命科学数据通常包括大量生物分子特征，例如基因组数据中的基因序列（成千上万基因），蛋白质组中的蛋白质表达水平，代谢组中的各种代谢物浓度等。

• **多种生物分子特征**：生命科学数据通常包括大量生物分子特征，例如基因组数据中的基因序列（成千上万基因），蛋白质组中的蛋白质表达水平，代谢组中的各种代谢物浓度等。

• **多维数据测量**：例如高通量测序产生的数据，其每个样本可能包含数万甚至数百万的基因测量值；单细胞RNA测序可以同时捕捉到上千个细胞内各个基因的表达情况。

• **多元生物信号数据**：例如从器官（如心脏或大脑）采集的生理信号，包括心电图（ECG）、脑电图（EEG）等，每一种信号又有大量的采样点和频率信息。

多模态 (Multi-Modal)

- 影像数据与基因组数据结合
- 电生理与行为数据结合：
- 代谢组学与影像数据结合
- 多元生物信号数据：



大气科学领域数据

多尺度 (Multi-Scale)

多尺度数据指数据在空间和时间上存在多种不同的尺度，反映大气过程在不同尺度上的演变和相互作用。具体定义如下：

- 空间尺度**：大气现象的空间尺度可能从局地（如城市、乡村）到区域（如大陆、海洋）再到全球。不同的天气现象，如龙卷风（局地尺度）和季风（区域或全球尺度），都具有不同的空间影响范围。
- 时间尺度**：大气现象在时间上的变化也具有多种尺度，从短期（如分钟级的阵风或雷暴）到长期（如季节性、年际变化甚至气候变化）。这种时间尺度的差异导致大气数据从高频（如秒级）到低频（如年级）不等。

多尺度特性使得大气科学研究需要处理跨越不同空间和时间尺度的复杂数据和过程，这些尺度间的相互作用对于理解天气和气候系统非常重要。

高维度 (High-Dimensionality)

高维度数据指数据包含大量的变量或特征，这些变量可能包括不同的大气要素或观测点。具体特征如下：

- 多个大气变量**：大气科学数据包括多个物理量，如温度、湿度、气压、风速、风向、降水量等。每一个变量都可以在不同的时间和空间点进行测量，这就使得整个数据集具有高维度。
- 网格数据**：在数值天气预报中，大气数据通常以三维网格的形式表示，每个网格点包含多种气象变量。这种形式的网格数据是典型的高维度数据，因为它涉及空间的三个维度（经度、纬度、高度）以及多种不同的物理量。
- 时间序列**：观测数据通常还具有时间维度，这使得数据维数进一步增加，例如每日、每小时或更高频率的测量数据形成了时间序列，从而增加了数据集的复杂性。高维度特性使得大气数据分析必须使用降维技术，如主成分分析（PCA）或流形学习，以提取数据中的重要特征并降低计算复杂性。

多模态 (Multi-Modal)

多模态数据指数据来自不同的观测方式或传感器，反映出同一大气现象的多种形式。大气科学中的多模态数据特征如下：

- 观测来源多样**：大气数据可以来源于地面观测站（如气象站）、雷达观测、卫星遥感、气球探空、无人机、浮标等，每种观测方式提供的数据类型不同，如卫星图像、雷达反射率、地面测量数据等。
- 数据形式多样**：数据可以是时间序列、图像、视频（如雷达回波动画）、图表（如垂直剖面）等。各自的数据模态反映大气现象的不同侧面，例如温度和湿度是数值型数据，而卫星提供的是图像数据。
- 物理特征的不同表达**：多模态数据可以反映同一大气现象的不同物理特征，如雷达图像描述降水强度，而气象站记录降水量、温度等，这些数据需要结合起来才能对大气过程形成完整的理解。



材料科学领域数据

多尺度 (Multi-Scale)

材料科学中的多尺度数据涉及从原子到宏观结构的多个尺度。这些不同尺度对于理解材料的性能和行为至关重要。具体包括：

•空间尺度:

- **原子/分子尺度**：材料的性质在原子或分子层次上的描述，如原子排列、键合性质、缺陷（如位错和空位）等，这些对材料的力学、电子和化学性能有决定性影响。
- **纳米尺度**：在纳米级别（例如晶粒尺寸、纳米结构等）观察材料的细微结构特征，例如晶粒边界、晶界等，这些特征对材料的物理性质（如导电性、导热性）有显著影响。
- **微米至宏观尺度**：微观结构（如相界面、晶体结构）到宏观结构（如复合材料中的各个成分的分布）。宏观尺度特征决定了材料的整体物理性能，如机械强度和韧性。

•时间尺度:

- **快速过程**：如原子扩散、相变，这些过程可能在毫秒或更短的时间内发生。
- **慢速过程**：如腐蚀、材料老化、应力松弛等，可能需要几小时、几天或更长的时间才能观察到。

多尺度数据的研究帮助材料科学家从不同尺度理解材料性能的来源，并开发出具有特定功能的新材料。

高维度 (High-Dimensionality)

高维度数据在材料科学中通常指包含大量变量和复杂特征的材料描述：

- **多物理量特征**：材料科学数据可能包含材料的化学组成、晶体结构、相组成、机械性能、导电性、导热性等多种物理量，每一个特征维度代表材料的不同属性或性质。例如，X射线衍射（XRD）可以捕捉晶体结构信息，拉曼光谱捕捉化学组成信息。
- **多种环境条件下的实验数据**：材料在不同条件下的表现（如温度、压力、湿度、应力等）产生的数据，可以包括数百甚至上千个变量。这些环境条件变化会影响材料的性质，因此实验需要跨越多个环境维度。
- **计算模拟数据**：从分子动力学、密度泛函理论（DFT）到有限元分析（FEM）等数值模拟中得到的数据，通常涉及大量的空间和时间节点，每个节点对应多个物理量，这些数据也是高度复杂和高维的。

多模态 (Multi-Modal)

多模态数据在材料科学中指材料的不同观测方式和数据类型的结合，这些方式提供了材料不同方面的表征和描述：

•实验数据与计算模拟数据:

- **实验数据**：来自不同表征技术的数据，如扫描电子显微镜（SEM）、透射电子显微镜（TEM）、X射线衍射（XRD）、拉曼光谱、原子力显微镜（AFM）等，这些技术提供材料的微观结构、形貌、晶体结构等信息。
 - **计算数据**：如密度泛函理论（DFT）模拟的电子结构、分子动力学（MD）模拟的原子运动和相变过程等。这些模拟结果可以补充实验数据，提供难以通过实验直接获取的细节。
- ### •图像、光谱和数值数据:
- **图像数据**：例如从电子显微镜得到的材料微观结构图像，揭示材料的形貌、晶界等。
 - **光谱数据**：例如X射线衍射光谱、红外和拉曼光谱，这些光谱数据用于分析材料的化学组成和相结构。
 - **数值数据**：实验测量和计算模拟中的各类物理参数（如硬度、导热系数、电阻率等）形成的数值数据，用于定量描述材料的性能。



流体力学领域数据

多尺度 (Multi-Scale)

流体力学中的多尺度数据反映了流体运动的不同物理尺度，在空间和时间上存在多种层次。这种多尺度特性是理解流体动力学现象和行为的关键：

•空间尺度：

- **分子尺度**：在微观尺度上，流体由大量分子组成，分子的碰撞和运动影响流体的宏观性质（如粘度和扩散）。
- **湍流结构尺度**：流体中的湍流存在从大尺度的能量注入到小尺度的耗散（例如涡旋、细涡结构），大尺度流动（如飞机机翼周围的流动）和小尺度流动（如湍流细涡）在动力学上紧密相关。
- **宏观尺度**：例如河流、海洋中的水流，风洞实验或建筑物周围的空气流动，这些宏观尺度描述了流体在大范围内的整体运动行为。

•时间尺度：

- **瞬态现象**：如声波、压力波和震荡等，这些现象在极短时间内发生，需要高频数据采样来捕捉其动态行为。
- **长期变化**：如河流的季节性水流变化、海洋洋流演化等，这些现象需要长时间观测数据，以捕捉其周期性或缓慢变化的特征。

流体中的多尺度相互作用非常重要，因为不同空间和时间尺度之间的相互作用决定了流体系统的整体行为。

高维度 (High-Dimensionality)

高维度数据在流体力学中是指流动系统的描述通常涉及大量的变量和复杂的物理特性：

- **多物理变量**：流体力学系统通常由多种物理量描述，如速度场、压力场、密度、温度、涡量等。这些物理量会在整个空间域和时间域内变化，从而形成高度复杂的系统。
- **空间网格节点**：数值模拟（例如计算流体力学，CFD）中，流体域通常被离散化为大量的网格单元，每个单元上都需要记录多个变量的数据，这导致数据的维度非常高。例如，三维网格中的每个点可能具有三个速度分量、压力、密度和温度等多个参数。
- **时间维度**：流体力学的数据通常也包含时间维度，这意味着我们不仅需要在空间上捕捉物理量的分布，还需要在时间上跟踪这些量的变化，这显著增加了数据维数和分析的复杂性。

高维度特性使得流体力学数据在分析和可视化时面临挑战，通常需要降维方法（如主成分分析、动态模式分解）来提取主要的流动特征，简化分析过程

多模态 (Multi-Modal)

多模态数据在流体力学中指不同类型的流体测量数据的组合，这些数据可以来自不同的测量设备、模拟方法或观测技术：

•实验观测与数值模拟：

- **实验数据**：如粒子图像测速（PIV）、激光多普勒测速（LDA）、流动可视化技术等，这些实验方法可以直接捕捉流体中的速度场、压力变化等信息。
- **数值模拟数据**：通过计算流体力学（CFD）模拟得到的速度、压力、温度等流场数据，通常可以补充实验无法直接观测的细节。

•不同的测量和传感方式：

- **视觉数据**：如流动的可视化图像（例如染料示踪、烟雾示踪），这些数据可以形象地展现流体的流动形态、涡流结构等。
- **光谱数据**：例如通过激光雷达或声学测量技术得到的频谱数据，可以用来分析流体中波动特性、湍流能量谱等。
- **传感器数据**：通过压力传感器、速度传感器等得到的数据，这些点测数据通常与模拟数据结合使用，以校准和验证模拟结果。



分子动力科学领域数据

多尺度 (Multi-Scale)

分子动力学中的多尺度数据涉及从原子级别的相互作用到更高层次的集体行为。研究分子系统时，不同尺度的描述对于理解物质性质和行为至关重要：

•空间尺度:

- **原子尺度:** 原子和分子是MD模拟的基本单元，描述分子间相互作用、化学键、原子间的位移等，这种尺度用于研究原子级别的动力学特性。
- **纳米尺度:** 在纳米尺度上，模拟的目标可以是较大的分子团簇、纳米颗粒或蛋白质复合物，这些结构在分子相互作用的基础上表现出集体行为，如蛋白质折叠、纳米粒子的凝聚等。
- **宏观表现:** 通过模拟大量原子或分子，MD研究可以间接推导出材料的宏观特性，例如粘度、热导率、扩散系数等宏观物性参数。

•时间尺度:

- **超短过程:** MD模拟的时间步长通常非常小（如飞秒级， 10^{-15} 秒），以捕捉原子振动、分子碰撞等快速过程。
- **长时间过程:** 长时间模拟可以用于研究蛋白质折叠、晶体生长、材料老化等过程，但这种尺度上的模拟往往需要很长的计算时间，一般通过增强采样技术（如偏置力法）来处理。

多尺度特性在MD模拟中非常重要，因为不同时间和空间尺度上的相互作用对系统的整体行为有着深远的影响。

高维度 (High-Dimensionality)

分子动力学中的高维度数据反映了系统的复杂性，通常涉及多个变量和特征：

- **原子坐标和速度:** MD模拟跟踪系统中每个原子的空间位置（坐标）和速度，因此如果模拟中有数十万甚至数百万个原子，数据的维数非常高。例如，一个含有10万原子的系统需要描述300,000个自由度（考虑到每个原子的 x, y, z 方向）。
- **力与能量参数:** 在MD模拟中，还需要计算每个原子受到的作用力、势能等，这些信息也是高维的，并且随时间变化。系统的总能量、温度、压强等全局变量也可能随时间动态变化。
- **多物理变量的耦合:** 在热力学系（如NVT、NPT等）条件下，温度、压强、体积等物理变量同时变化，这增加了系统的维度和复杂性。

多模态 (Multi-Modal)

多模态数据在分子动力学中指通过不同方式获取的数据，提供对分子系统的多角度理解：

•模拟数据和实验数据:

- **模拟数据:** MD产生的数据包括原子坐标、速度、相互作用能等，它们可以用于研究系统的微观行为。
- **实验数据:** 例如核磁共振（NMR）、X射线晶体衍射、电子显微镜（EM）等实验技术提供了分子或蛋白质的结构信息。这些实验结果可以作为MD模拟的验证或用于对初始结构的建模。

•不同形式的的数据:

- **结构数据:** 分子和蛋白质的三维结构信息通常以PDB（Protein Data Bank）文件形式表示，包含原子坐标、化学键等。
- **时间序列数据:** 原子位置、系统总能量、温度、压力等随时间变化的数据是MD模拟的主要输出之一。这些时间序列数据帮助研究人员了解分子系统的动力学过程。
- **统计与热力学数据:** 通过对模拟数据进行处理，可以获得宏观性质（如自由能、扩散系数、反应速率常数等），这些数据用于从分子行为推导出系统的热力学特性。



基础科学领域数据

分子动力学 (Molecular Dynamics, MD)

- **数据形式:** 原子坐标、速度、加速度、势能等。 **尺度:** 时间尺度: 从飞秒 (fs) 到纳秒 (ns) 级别。
- **空间尺度:** 在纳米 (nm) 级别, 通常考虑包含数千到数百万个原子。
- **维度:** 三维空间坐标, 通常每个原子有 (x, y, z) 坐标 (3 维度)。
- 时间序列数据, 可扩展为 t 维度。
- **模态:** 多模态数据, 结合坐标、速度、势能、电荷等信息。不同模态的数据可能表示结构信息 (原子坐标)、动力学信息 (速度、加速度) 和能量信息 (势能、键能等)。

流体力学 (Fluid Dynamics)

- **数据形式:** 压力、速度场、密度、温度等物理量的分布。 **尺度:** 空间尺度: 可在毫米到米的范围内, 取决于模拟问题的大小。
- **时间尺度:** 从毫秒到秒的范围。
- **维度:** 通常在二维或三维空间中表示流体的状态, 数据可能是 (x, y, z) 的三维空间网格。
- 对于时间依赖的流动, 还需要加上时间维度。
- **模态:** 速度场 (例如 u, v, w 分量)、压力场、密度场、温度场等。对于每一个时空点, 可以包含多种模态的物理量。

空气动力学 (Aerodynamics)

- **数据形式:** 压力分布、气流速度、力与力矩系数等。 **尺度:** 空间尺度: 通常为米到几十米的范围, 用于模拟飞行器、汽车等大型物体。
- **时间尺度:** 静态 (稳态) 问题通常无时间维度, 动态问题则在秒级别。
- **维度:** 需要描述三维空间中的速度场、压力场, 通常是三维 (x, y, z) 的网格。
- 对于动态模拟, 还需要时间维度。
- **模态:** 速度 (通常为 u, v, w 三个分量)、压力、湍流量 (如湍流动能) 等。
- 可能还涉及边界层特性、紊流模型等。

空间分辨率: 所有这些领域的的数据都需要网格化的空间分布, 分辨率取决于模拟的物理特征及其尺度, 通常为均匀或非均匀网格。

时间维度: 动态问题需要时间序列数据, 这样可以捕捉系统状态的变化。

数据模态: 数据可能是单模态 (如纯粹的速度场) 或者多模态 (如速度、压力、温度的组合), 需要不同的网络结构来处理, 例如卷积神经网络 (CNN) 可以很好地处理空间数据, 而循环神经网络 (RNN) 或变换器 (Transformer) 可以处理时间序列。



科学研究数据的复杂性

数据复杂性高

多尺度/高维度/多模态

动态变化/时间依赖

数据量庞大，有效数据少

信噪比低/数据质量差
缺失值
暴露偏差问题

Small signals

Rare events / outlier

Incomplete data

Data bias

特征提取和数据标注困难



数据选择

应用领域	生成数据量	有用数据比例	数据类型	描述
高能物理实验	100TB/sec	小于1%	碰撞事件数据	大型强子对撞机 (LHC) 中筛选稀有事件
天文学中的天体观测	每晚数百TB	约 0.01%	天体图像和光变曲线	筛选超新星爆发或近地小行星
地震检测	每天数TB	小于 1%	地震波形数据	筛选有用的地震事件信息
医疗影像处理	每天数TB	小于 5%	CT/MRI/PET图像	筛选出含有可疑病灶的医疗影像数据
海洋科学中的异常检测	每天数百TB	约 0.1%	海洋传感器数据	筛选极端海洋现象，如异常波浪或海啸
工业预测性维护	每秒数GB	约 0.5%	机器传感器数据	筛选可能的设备故障信号
自动驾驶汽车场景分析	每小时数十TB	约 0.1% ~ 0.5%	图像/激光雷达和传感器数据	筛选危险场景或特殊情况数据
药物发现和化学筛选	数千亿分子结构	约 0.01% ~ 0.1%	分子结构/化学性质数据	通过虚拟筛选和机器学习模型筛选潜在候选药物分子
生命科学中的基因组测序	每个项目数PB	小于 5%	基因组序列数据	筛选出与特定疾病或表型相关的基因组变异数据
极端气候预报	每天数10TB	小于1%	气象观测和模拟数据	筛选极端气候事件，如台风，热浪和暴雨




数据选择的方法

方法名称	描述	应用领域	特点
自编码器	利用编码-解码过程计算重建误差， 高误差样本代表稀有或异常事件	高能物理实验、天文学、地震检测	无监督学习，适合自动提取稀有 $L(x) = \ x - g(f(x))\ ^2$
分层抽样	根据特征分布对数据分层抽样，确保代表不同类别和特征的数据	药物发现、生命科学基因组测序	保证覆盖不同类别特征，避免对稀有事件的忽略 数据集 D 分成 K 个类别 $p_i = \frac{n_i}{N}$ 每个类别 i 中抽取 $m_i = p_i \times M$ 个样本，
主动学习	根据模型不确定性选择标注样本，充实训练数据	药物发现、医疗影像处理	减少标注工作量，提高数据标注效率 $H(y x, \theta) = - \sum_{i=1}^K P(y_i x, \theta) \log P(y_i x, \theta)$
孤立森林	递归分割数据识别异常点，筛选出潜在无用数据	工业预测性维护、地震检测	有效的轻量级异常检测，适合大规模传感器数据 $s(x) = 2^{-\frac{E(h(x))}{c(n)}}$ $E(h(x))$ 表示数据点 x 在多棵孤立树中的平均路径长度。
基于密度的聚类	划分高密度和低密度区域，低密度区域的数据被视为噪声或异常	海洋科学、大气科学	适用于检测异常和低频事件，尤其是极端现象 $N_\epsilon(x_i) = \{x_j \in X \mid d(x_i, x_j) \leq \epsilon\}$
生成对抗网络	生成背景数据与真实数据对比，筛选出异常前景数据	药物化学筛选、大气科学	能捕捉数据的分布，适合找出超出背景的前景数据
基于置信度的样本剔除	训练初始模型，筛选低置信度的样本，丰富模型的训练集	自动驾驶汽车、医疗影像处理	关注模型预测不确定的样本，提升模型性能
LSTM时间序列异常检测	使用 LSTM 学习时间序列正常模式，识别无法匹配的异常样本	工业预测性维护、地震检测	适合处理具有时间依赖性的传感器数据
Transformer残差分析	使用 Transformer 进行序列预测，分析较大残差样本	大气科学、基因组序列分析	捕捉长距离依赖关系，适合复杂序列数据的筛选




Data generation

Minimize difference between input and output during training



1. 潜在空间捕捉了数据的核心特征
2. 相邻点表示相似的数据
3. 解码器根据潜在特征生成数据




变分自编码器


损失函数

$$\mathcal{L}_{VAE} = \underbrace{\mathbb{E}_{q(z|x)}[-\log p(x|z)]}_{\text{重构损失}} + \underbrace{D_{KL}(q(z|x) \parallel p(z))}_{\text{KL散度}}$$

作用

1. 能进行数据的降维和特征提取
2. 能用于生成新的类似样本






Generative Adversary Network

生成器 G: 从一个简单的随机噪声（例如高斯噪声或均匀分布）中生成逼真的样本。生成器的目标是“欺骗”判别器，使其认为生成的样本是真实的

$$\mathcal{L}_G = -\mathbb{E}_{z \sim p_z(z)} [\log D(G(z))]$$

判别器 D: 区分生成的数据和真实数据。它的目标是最大限度地正确判断输入数据是真实数据还是生成的数据。

$$\mathcal{L}_D = -\mathbb{E}_{x \sim p_{\text{data}}(x)} [\log D(x)] - \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$



GAN 的训练目标是通过**博弈论**的方式，使生成器和判别器之间相互对抗，生成器试图生成逼真的样本以欺骗判别器，而判别器试图区分真实数据和生成数据。最终，生成器生成的样本应该难以与真实数据区分开来

扩散过程 (Diffusion Process) :

扩散模型的核心思想是通过逐步添加噪声来破坏分子的表示 (例如原子坐标、键关系等), 然后学习逆扩散过程, 将其逐步还原为无噪声的分子结构

前向扩散 (Forward Diffusion) :

对分子结构添加噪声, 例如通过将分子坐标逐步扰乱或修改分子图上的边连接

逆向扩散 (Reverse Diffusion) :

利用神经网络学习从噪声分布中重建无噪声分子

在逆向扩散过程中, 通常使用神经网络来预测每个时间步的噪声

训练和损失函数


扩散模型的训练目标是最小化在每个时间步中重建无噪声分子的误差

重建损失 (Reconstruction Loss) :

衡量逆向扩散过程中, 生成的分子和原始分子之间的距离。例如, 三维坐标上的L2距离或图结构的相似性损失。

属性引导 (Property-guided Loss) :

为确保生成的分子具有特定性质, 可以引入额外的损失函数来引导模型生成具有期望性质的分子, 例如通过引入预测分子属性的辅助网络或直接优化分子性质的损失



扩散模型在分子生成中的优势

高效的样本生成:

扩散模型在生成分子时能够处理复杂的分子结构, 包括环状结构、稀有元素组合等

灵活的条件生成:

模型可以通过条件输入控制分子的物理化学性质, 生成符合目标性质的分子

高质量的生成结果:

扩散模型能够生成更符合化学规则的分子, 生成的分子通常具有较高的化学可行性和有效性

Data refinement



数据精炼的代表性方法

超分辨率图像重建

(Super-Resolution Image Reconstruction)

将低分辨率图像转换为高分辨率图像，从而增加细节和数据质量

数据融合与多模态增强，将来自不同来源（如MRI、CT）的多种图像融合，生成具有高分辨率和丰富信息的图像

数据驱动模拟与建模 (Data-driven Simulation and Modeling)

结合计算机模拟与已有实验数据，通过扩增现有的数据集，产生更高质量或更多样化的数据

图像去噪与补全 (Denoising and Inpainting)

减少噪声和缺失数据的影响



科学研究数据的复杂性

数据复杂性高

多尺度/高维度/多模态

动态变化/时间依赖

数据量庞大，有效数据少

信噪比低/数据质量差

缺失值

暴露偏差问题

特征提取和数据标注困难

Data is expensive



数据可标注性假设 - hypothesis

Smoothness Assumptions

两个数据样本在特征空间中的某个高密度区域足够接近，那么它们的标签应相同或非常相似

给定特征空间中的两个样本 x_i 和 x_j

如果 $\|x_i - x_j\| < \epsilon$ 且 $p(x) > \delta$, 则 $|y_i - y_j| < \eta$

Cluster Assumptions

特征空间中存在稠密区域和稀疏区域，稠密区域内的数据点自然地形成一个簇，同一簇内的样本应有相同的标签

特征空间内存在簇 C_k , 其中 $x_i, x_j \in C_k$

$$y_i = y_j, \quad \forall x_i, x_j \in C_k$$

Low-density Separation Assumptions

类别之间的决策边界往往位于稀疏、低密度区域。如果决策边界位于高密度区域，则会将一个高密度簇切分为两个类别，从而违反平滑性和聚类假设

决策边界 B 应位于低密度区域 $p(x)$ 较小的地方

$$B = \{x : f(x) = 0\}, \quad \text{且 } p(x) < \delta \text{ 在 } x \in B$$

Manifold Assumptions

高维数据倾向于位于一个低维流形上，尽管真实世界的数据可能存在于高维空间，但它们实际上可以被捕捉到一个较低维的流形上

假设数据点 $x \in \mathbb{R}^D$ 实际上位于一个低维流形 $\mathcal{M}$ 上,

$$x = g(z), \quad z \in \mathbb{R}^d, \quad d \ll D$$

其中 $g: \mathbb{R}^d \rightarrow \mathbb{R}^D$ 是一个嵌入函数

其中流形的维度为 $d \ll D$



数据自动化标注方法 - approach





》 consistency regularization

》 Pseudo Labeling

》 Label Propagation

• Π -model

• Mean teachers



MixUp

[self-supervised learning](#) methods, such as SimCLR, BYOL, SimCSE, etc. Different augmented versions of the same sample should result in the same representation

assigns fake labels to unlabeled samples based on the maximum softmax probabilities predicted by the current model and then trains the model on both labeled and unlabeled samples simultaneously in a pure supervised setup


construct a similarity graph among samples based on feature embedding. Then the pseudo labels are “diffused” from known samples to unlabeled ones where the propagation weights are proportional to pairwise similarity scores in the graph

Lee, D.-H. et al. Pseudo-label: the simple and efficient semi-supervised learning method for deep neural networks. In *ICML Workshop on Challenges in Representation Learning* (2013).

1.Zhou, D. et al. Learning with local and global consistency. In *Advances in Neural Information Processing Systems* 16, 321–328 (2003).



数据自动化标注方法- active learning





Data representation

紧凑性/可区分性/可解耦性/上下游任务的泛化性

几何先验/自监督学习/语言建模



数据表征

几何深度学习方法

图神经网络（GNN）在处理具有几何和关系结构的数据方面具有重要作用，它们通过引入归纳偏置，利用局部信息来进行深度学习；
适用：分子/材料科学

自监督学习

在只有少量标注样本或标注成本高昂的情况下，自监督学习通过利用标注和未标注数据来提升模型的学习能力和性能

数据表征

类大语言模型方法

掩码语言建模（MLM）是一种流行的自监督学习方法，适用于自然语言和生物序列的学习，两者在结构和功能上的相似性推动了相互的发展




神经算子 (neuron operator)

标准神经网络在科学应用中表现不足，因为它们假设固定的数据离散化，而神经算子通过在函数空间之间学习映射，能够实现对不同离散化的泛化，具有离散化不变性。
适用：





数据表征 @ GNN

Molecules as graphs



chemical sciences



diverse applications from
traffic networks to
medicine

graph
convolutions

Duvenaud, D., et al., *NeurIPS* 28, 2015.

machine learning methods

Input Graph

GNN blocks

Transformed Graph

Classification layer

Prediction
node, edge, or global
predictions

Graph-level task

goal is to predict the
property of an entire graph

Node-level task


predicting the identity or role of
each node within a graph

Edge-level task

edge prediction/link prediction

Layer N

Layer N + 1





transformer

TRANSFORMER EXPLAINER


Examples ▾

Data visualization empowers users to


Generate

Temperature ?

1



数据表征 @ molecular self attention





数据表征 @ 自监督学习

传统分子表征

分子指纹

1. 用于表示分子结构特征的二进制或数字化表示形式
2. 通过捕捉分子的结构信息、功能团、化学环境等特征


分子描述符

1. 用来量化和描述分子结构特征的数值指标
2. 表征分子的化学和物理性质
MW/LogP/HBA/HBD/PSA/RB/AR/MV/SYM/NBA

拓扑特征

1. 描述分子图中原子和化学键的结构和关系的特征
2. 捕捉分子内部的连接性和结构模式

自监督学习 (self-supervised learning, SSL) 范式





数据表征 @ 神经算子

定义： 通过神经网络来学习并逼近算子映射的模型。它的目标是模拟从一个无限维函数空间到另一个函数空间的映射关系。与传统神经网络不同，神经算子不仅仅是在有限维向量空间中进行映射，而是针对涉及偏微分方程（PDEs）等物理问题中复杂函数之间的关系


Fourier 神经算子 (FNO, Fourier Neural Operator)

基于核的神经算子 (Kernel Neural Operator)

深度学习 PDE 方法 (Deep Learning for PDEs)

Foundation Model for scientific research

Numerical Integration and Machine Learning work in Opposite Directions





Surrogate Model for scientific research

核心思想：

通过构建近似模型，来代替计算复杂度极高的真实物理模型或实验过程，以加速优化、仿真、推理等任务

加速优化与仿真

快速逼近复杂系统的输入与输出之间的关系，减少对昂贵的数值模拟或实验的依赖。通常用于需要大量计算的任务，如参数优化、设计探索、仿真等

数据驱动建模

基于收集到的数据构建，通过利用已有的数据来学习物理模型的规律。与基于方程式的物理模型相比，它是数据驱动的，更关注于通过统计和机器学习方法来学习输入和输出的关系


不失准确性的简化

需要确保在精度和计算开销之间的平衡，特别是在确保不失去关键物理信息或预测准确性的前提下。

数据驱动的计算机模拟




科学发现

- 发现新材料，高温超导材料，量子材料
- 发现新的治病靶点，发现新的药物
- 发现脑功能映射
- 发现新的微生物菌群



求解/加速科学计算


- 更精确的天气预报、气候预测，辅助碳中和政策制定
- 流体仿真（用于汽车设计、飞机设计、能源等）
- 分子动力学仿真（用于材料设计、分子设计）
- 天文仿真（恒星演化、星系演化）



附录

流式细胞仪





流式细胞术广泛用于分析细胞表面和细胞内分子的表达、鉴定并确定异质细胞群中的不同细胞类型、评估分离亚群的纯度以及分析细胞大小和容积。

基于激光的技术，用于检测细胞或颗粒特性

流式细胞数据通常是高维数据，每个维度代表不同的细胞表面标志物或荧光强度值。输入数据形式为矩阵 $X \in \mathbb{R}^{N \times D}$ ，其中 N 是细胞的数量， D 是每个细胞的特征维度（标志物数量）。

在基于流式细胞仪数据进行细胞亚型分析和门控时，信号噪音是常见且不可避免的问题。信号噪音可能来自于仪器误差、样品质量差异、荧光染料的非特异性结合、或其他实验误差。

细胞分类与亚群识别

$$L_{\text{cross-entropy}} = - \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(p_{i,c})$$

异常细胞检测

$$L_{\text{reconstruction}} = \frac{1}{N} \sum_{i=1}^N ||X_i - \hat{X}_i||^2$$

自动化门控策略生成


$$L_{\text{k-means}} = \sum_{i=1}^N ||X_i - \mu_{c(i)}||^2$$

细胞功能预测

预测的是细胞的未来状态
(如细胞增殖或死亡)

$$L_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Super-Resolved Fluorescence Microscopy



一种特殊的光学显微镜技术。它利用的是荧光色素在一定波长的光激发下发光的能力。通过抗体染色或荧光蛋白标记，可以用这种荧光色素标记感兴趣的蛋白质。这样就可以确定单分子物种的分布、数量及其在细胞内的定位。

2014年10月8日，诺贝尔化学奖



埃里克·贝齐格



斯特凡·黑尔



威廉·莫纳

分辨率极限突破：传统光学显微镜受到光的衍射极限的限制（阿贝极限），通常无法分辨小于200纳米的结构。超分辨显微镜的目标是突破这个极限，但如何精确定位单分子的位置、减少噪声干扰等是主要挑战。

荧光漂白与光毒性：荧光染料会在光照下逐渐漂白，影响长时间观测的效果，且可能对活细胞产生光毒性，这限制了活体成像和重复实验的次数。

信号与背景噪声的处理：超分辨显微技术需要对单分子的荧光信号进行高精度定位，如何在强背景噪声中提取有效信号，是一个主要问题。

图像重建：一些超分辨方法如STORM（随机光学重建显微镜）和PALM（光活化定位显微镜）依赖于对多个单分子图像的叠加进行重建，因此需要复杂的图像处理和分析算法，这对计算资源和算法精度提出了很高要求。

标记方法：对样品的荧光标记需要精准，但荧光标记往往会引入结构上的改变或影响样本的生物活性。如何选择合适的荧光探针，兼顾高信噪比和生物相容性，是重要的考虑因素。

数据处理速度与大数据量：由于超分辨显微镜采集的数据量大，处理这些数据并生成高清晰度的图像需要高效的数据处理能力。

图像去噪与增强：Cryo-EM 采集到的图像通常噪声较大，图像的质量直接影响最终的分辨率和结果。人工智能，尤其是深度学习技术，可以用于去噪和图像增强，从而提高分辨率并帮助更准确地识别蛋白质结构。

颗粒自动拾取：Cryo-EM 样品的原始图像包含大量的颗粒（例如蛋白质或其他生物分子），自动拾取这些颗粒对于加快数据处理非常关键。AI 模型可以显著提高颗粒检测的准确性和效率，相比于传统的手动或半自动方法，能够更快地从大量数据中提取目标颗粒。

3D 重构：Cryo-EM 的目标是从 2D 图像中重建 3D 分子结构，AI 技术可以用于加速和提高 3D 重构过程。特别是深度神经网络可以帮助从复杂的数据中学习最佳的 3D 重构方式，减少手动处理的时间并提高重建精度。

异质性处理：生物分子在采集过程中可能具有不同的构象状态（异质性），这会导致重构复杂性增加。AI 可以用于识别和分类这些不同的构象状态，从而在重构过程中更好地处理异质性。

结构验证与解释：AI 可用于验证从 Cryo-EM 数据中得到的 3D 结构的准确性，帮助识别模型中的错误。此外，AI 可以通过结构预测和对比，辅助对生物分子功能的解释。

加速计算和自动化流程：AI 可以通过对数据处理管道的加速和优化，实现端到端的自动化流程，降低操作的复杂度，提升高分辨率结构解析的效率。

2017年，诺贝尔化学奖

冷冻电镜（Cryo-EM）是一项获得诺贝尔奖的成像技术，使科学家能够以亚纳米分辨率观察生物分子。






高通量细胞扫描仪



智能化细胞机械臂




细胞自动化精准挑选



高产率细胞AI定位






操作平台



质谱仪



质谱仪



■ De novo analysis



□ Missing ions

□ Noise

■ Spectrum library search

□ Incomplete

■ Database search



Ratner, A. J. et al. Data programming: creating large training sets, quickly. In *Advances in Neural Information Processing Systems* **29**, 3567–3575 (2016)

Ratner, A. et al. Snorkel: rapid training data creation with weak supervision. In *International Conference on Very Large Data Bases* **11**, 269–282 (2017).

This paper presents a weakly-supervised AI system designed to annotate massive amounts of data using labeling functions.

Tran, K. & Ulissi, Z. W. Active learning across intermetallics to guide discovery of electrocatalysts for CO₂ reduction and H₂ evolution. *Nat. Catal.* **1**, 696–703 (2018)

Jablonka, K. M. et al. Bias free multiobjective active learning for materials design and discovery. *Nat. Commun.* **12**, 2312 (2021)

Roussel, R. et al. Turn-key constrained parameter space exploration for particle accelerators using Bayesian active learning. *Nat. Commun.* **12**, 5612 (2021)

Bileschi, M. L. et al. Using deep learning to annotate the protein universe. *Nat. Biotechnol.* **40**, 932–937 (2022)

Barkas, N. et al. Joint analysis of heterogeneous single-cell RNA-seq dataset collections. *Nat. Methods* **16**, 695–698 (2019)