



人工智能在药物发现中的应用

复旦大学人工智能创新与产业研究院研究员
徐盈辉

未来25年，这125个问题将让科学家“大伤脑筋”

这125个问题，其中涉及生命科学的问题占46%，关系宇宙和地球的问题占16%，与物质科学相关的问题占14%以上，认知科学问题占9%。其余问题分别涉及数学与计算机科学、政治与经济、能源、环境和人口等。

一场正在发生的科研范式变革



《 Science 》刊登麻省理工
AI药物逆合成设计论文，AI合
成了**15个**药物分子

2019.3

利物浦大学使用AI发现**4种**可
传导锂的新固态材料，可提
供更长续航能力


2021.5

Deepmind宣布开放包括多
个动物、植物的**2亿**个蛋白质
结构的预测结果


2022.7

中心法则

一生二，二生三，三生万物



Chromosomes and genes




autosomes


sex chromosomes

U.S. National Library of Medicine

Genes: segments of DNA within chromosomes

Genes provide code for proteins
But 99% of genes are “non-coding!”





楠柚桥林 bilibili

灵犀妈 bilibili





中心法则

DNA（脱氧核糖核酸）：遗传信息存储在DNA分子中，存在于细胞的细胞核内。


转录（Transcription）：在转录过程中，DNA上的遗传信息被转录成**mRNA（信使RNA）**。这一过程由RNA聚合酶催化进行。mRNA分子携带着DNA中的遗传信息，用于指导蛋白质的合成。

mRNA的加工：在转录后，mRNA会经历一系列加工过程，如加上5'帽、剪接去除内含子、添加3'多腺苷酸尾巴等，使其成为成熟的mRNA，准备进行翻译。


翻译（Translation）：成熟的mRNA被运送到**核糖体**，在那里根据mRNA上的密码子序列，指导**氨基酸**的连接，最终合成特定的**蛋白质**。翻译过程中，**tRNA（转运RNA）**将特定的氨基酸带到核糖体，并依据mRNA上的密码子序列将氨基酸连接成多肽链。

蛋白质合成：经过翻译后，最终形成功能性蛋白质，执行细胞中的各种任务。

DNA 转录与翻译




Transcription and Translation




转录&翻译

Transcription: DNA $\rightarrow$ RNA





© 2017 Terese Winslow LLC

Translation: RNA $\rightarrow$ Protein







DNA → Pre-mRNA







Gene to transcribe

RNA polymerase: enzyme that binds to promoter region and uses DNA template to synthesize complementary RNA

Figure 7-9 Essential Cell Biology 3/e (© Garland Science 2010)




Nucleobases
of DNA




Nucleobases
of RNA

Pre-mRNA → mRNA




mRNA splicing: remove introns (non-coding regions), splice together exons (coding regions)

mRNA -> Proteins




Ribosome: cell organelle that synthesizes proteins

tRNA: molecule carrying amino acids corresponding to each 3-nucleotide codon



Protein being synthesized

mRNA -> Proteins




Codon -> amino acid mapping

		Second letter				
		U	C	A	G	
First letter	U	UUU } Phe UUC } UUA } Leu UUG }	UCU } UCC } Ser UCA } UCG }	UAU } Tyr UAC } UAA } Stop UAG } Stop	UGU } Cys UGC } UGA } Stop UGG } Trp	U C A G
	C	CUU } CUC } Leu CUA } CUG }	CCU } CCC } Pro CCA } CCG }	CAU } His CAC } CAA } Gln CAG }	CGU } CGC } Arg CGA } CGG }	U C A G
	A	AUU } AUC } Ile AUA } AUG } Met	ACU } ACC } Thr ACA } ACG }	AAU } Asn AAC } AAA } Lys AAG }	AGU } Ser AGC } AGA } Arg AGG }	U C A G
	G	GUU } GUC } Val GUA } GUG }	GCU } GCC } Ala GCA } GCG }	GAU } Asp GAC } GAA } Glu GAG }	GGU } GGC } Gly GGA } GGG }	U C A G
						Third letter

Epigenomics

Study of processes that regulate how and when genes are turned on and off (“gene expression”)

- E.g. **transcription factors**: proteins that bind to the promoter and other noncoding regions, can enhance or repress transcription
- E.g. **DNA methylation**: addition of large methyl group to promoter region makes it difficult for proteins to bind -> represses transcription
- E.g. **Histone modification**: addition or removal of acetyl groups affects charge interaction to relax or tighten chromatin structure (easier for proteins to bind)



Transcriptomics

- Study of the transcriptome (the RNA of a cell)
- One reason of interest: Harder to measure proteins (the functional molecules!), but we can sequence RNA as a (highly imperfect) proxy for proteins to quantify cell state

Proteomics


- Study of the proteins in a cell

Data: DNA microarray

Produces relative expression of genes in normal vs disease tissue samples

Isolate mRNA (“expressed genes”) from tissue samples and synthesize complementary DNA (cDNA).

Use fluorescent tags to label cDNA from normal tissue green, and from disease tissue red



Each spot of DNA microarray contains single-stranded DNA corresponding to a gene


cDNA will bind to the corresponding DNA strands on microarray. Color indicates ratio of cDNA (relative gene expression) in the normal vs disease tissue

Figure credit: http://www.vce.bioninja.com.au/_Media/microarray_med.jpeg

Data: RNA-seq

More recently in 2010s,
single-cell RNA-seq!

Produces readout of
mRNA content in a
tissue sample



Map back to reference
genome for analysis

Now standard approach
for transcriptomics study

Data: ChIP-seq

Produces reads of DNA sequences where a protein binds





Figure credit:
<https://www.france-genomique.org/wp-content/uploads/2019/08/CHIP-selon-Park-1-e1566900408602.jpg>

Use NGS to read-out remaining DNA sequences

Visualize distribution of locations on DNA where protein binds



OPEN

Effective gene expression prediction from sequence by integrating long-range interactions

Žiga Avsec¹✉, Vikram Agarwal^{2,4}, Daniel Visentin^{1,4}, Joseph R. Ledsam^{1,3},
Agnieszka Grabska-Barwinska¹, Kyle R. Taylor¹, Yannis Assael¹, John Jumper¹, Pushmeet Kohli¹✉
and David R. Kelley²✉

精准地通过超长非编码 DNA 序列预测基因的表达。

帮助理解疾病相关的突变

- 从 DNA 序列预测基因表达是一个尚未解决的关键问题，尤其是如何整合远距离相互作用来提高预测准确性。
- 理解非编码 DNA 如何决定不同细胞类型中的基因表达，以及如何改进对人类遗传变异影响基因表达的预测。



Enformer 模型的数据构成

- **转录因子 ChIP-seq 数据**: 用于衡量转录因子在基因组上的结合位点和结合强度，反映了转录因子对基因表达的调控作用，是模型预测的目标之一，以了解模型对转录因子调控基因表达的预测能力。
- **组蛋白修饰 ChIP-seq 数据**: 提供了组蛋白修饰的信息，组蛋白修饰状态与基因的活性状态密切相关，通过这些数据可以评估模型对组蛋白修饰影响基因表达的预测准确性。
- **DNase-seq 或 ATAC-seq 数据**: 这些数据反映了基因组的可及性，可及性区域往往包含调控元件，模型预测这些数据有助于分析其对基因表达调控的预测效果。
- **CAGE 数据**: 主要用于测量转录起始位点 (TSS) 的活性，通过 CAGE 数据可以评估模型对基因转录起始活性的预测能力，进而判断模型在基因表达预测方面的性能。例如，通过比较模型预测的 CAGE 数据与实际测量的 CAGE 数据之间的相关性，来衡量模型的准确性。



Enformer 模型的损失函数

假设我们有一组观测数据 $y_1, y_2, \dots, y_n$ 以及对应的模型预测 $\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_n$, 其中 $\hat{\lambda}_i$ 是第 i 个数据点的预测值, 代表该数据点的 Poisson 分布的参数 (即事件发生的期望次数)。Poisson 分布的概率质量函数 (PMF) 为:



$$P(y_i | \hat{\lambda}_i) = \frac{\hat{\lambda}_i^{y_i} e^{-\hat{\lambda}_i}}{y_i!} \quad \Rightarrow \quad \log P(y_i | \hat{\lambda}_i) = y_i \log(\hat{\lambda}_i) - \hat{\lambda}_i - \log(y_i!)$$

损失函数:


$$\mathcal{L}(\hat{\lambda}_1, \hat{\lambda}_2, \dots, \hat{\lambda}_n) = - \sum_{i=1}^n \left[y_i \log(\hat{\lambda}_i) - \hat{\lambda}_i \right]$$

数据的计数特性: 在许多生物学任务中, 数据通常呈现出计数特性, 比如基因表达数据、细胞计数、疾病事件发生的次数等。Poisson分布是用来建模这些计数数据的经典分布, 它描述了单位时间或单位空间内某个事件的发生次数。

适应稀疏数据: 生物学数据往往具有稀疏性, 尤其是在基因表达分析或蛋白质组学等领域, 许多基因或蛋白质的表达量可能为零或接近零。Poisson分布在描述稀疏数据时表现得特别好, 因为它能够有效地处理零值和低频事件。




Output: Genomics tracks



- 输入数据类型：算法的输入是 DNA 序列。
- 感受野 (Receptive field)：图中对比了 Basenji2 和 Enformer 的感受野大小。Basenji2 的感受野为 20 kb, 而 Enformer 的感受野为 100 kb。这意味着 Enformer 能够考虑更长范围的 DNA 序列信息，有助于捕捉长距离的基因调控关系。



Enformer 模型的结果





RNA 干扰

RNAi

RNAi现象早在1993年就有报道: 将产生紫色素的基因转入开紫花的矮牵牛中,希望得到紫色更深的花,可是事与愿违,非但没有加深紫色,反而成了白色。当时认为这是矮牵牛本来有的紫色素基因和转入的外来紫色素基因都失去了功能, 称这种现象是“共抑制”（导入的基因和其相似的内源基因同时都被抑制）。后来在其他植物, 以及真菌中也有类似的现象发生。



siRNA

小干扰RNA (small interfering RNA, siRNA) 生物学最重要生物技术之一，是发现能够通过一种被称为RNA干扰(RNA interference, RNAi)的现象来调节基因的表达。siRNA可用作研究体内和体外单基因功能的工具，是一类有吸引力的新型疗法，特别是针对治疗癌症和其他疾病的不可成药靶点。





siRNA小分子药物作用机理

RNA干扰 与 小干扰RNA 的发展历程

RNA interference, RNAi small interference RNA, siRNA


RNAi一种天然存在的是细胞内调控基因表达机制，可抵御外来核酸的入侵和控制基因表达。
siRNA是其中一种主要作用分子





siRNA小分子药物作用机理

siRNA的作用机理与优势



siRNA是生物针对外源侵入基因所表达的双链RNA，它通过与目的基因序列的编码互补，从而诱导降解相对应的信使核糖核酸 mRNA，阻止mRNA翻译成蛋白质

siRNA小分子药物优势

- **安全性：** siRNA作用于基因表达的翻译后阶段，因此不与DNA相互作用，从而避免了基因治疗常见的突变和致畸风险
- **高效性：** 小分子疗法和单克隆抗体相比具有先天优势，因为siRNA通过与mRNA完成Watson-Crick碱基配对来执行其功能，而小分子和单克隆抗体药物需要识别蛋白质的3D空间构象
- **高特异性：** siRNA只能沉默同源基因，而无关基因不受影响，且在siRNA序列中配对的19~21nt中仅需改变一个核苷酸，就可使该siRNA消除靶基因的沉默效应
- **低成本：** siRNA化学合成简单，且与蛋白质或抗体相比，siRNA无需经过表达、纯化等繁琐的步骤；因此生产成本更低





siRNA小分子药物设计

siRNA设计的一般步骤


- ❑ **目标基因选择**：确定需要沉默的基因，并获取其mRNA序列。
- ❑ **siRNA选择**：在目标mRNA序列中选择适当的区域用于设计siRNA。通常选择21-23个核苷酸长度的序列，主要考虑siRNA的化学结构、序列特异性以及避免潜在的非特异性结合。
- ❑ **化学修饰**：对siRNA进行化学修饰以提高其稳定性、减少免疫反应，优化其药代动力学特性。
- ❑ **递送系统开发**：开发有效的递送系统，确保siRNA可到达目标组织与细胞，避免被体内清除机制快速清除。
- ❑ **体外实验验证**：通过体外细胞验证siRNA对目标mRNA的沉默效率、特异性与安全性。




临床验证



C SNP-discriminative design



d Unimolecular multi-targeting scaffold



a. 支架设计模型: siRNA药物设计的化学支架, 决定siRNA的稳定性、组织分布特性以及最终的沉默效率

b. siRNA活性逆转: 使用特定单链寡核苷酸抑制或逆转siRNA介导的沉默效果, 可用于减少siRNA非预期的副作用或毒性

c. 单核苷酸多态性区分设计: siRNA特殊设计策略, 用于提升对特定基因的靶向特异性

c. 单一分子多靶向支架: 特殊的设计策略, 使得单一分子可以沉默多个基因

未来方向：

- 新型化学修饰
- 递送系统创新
- 多靶点siRNA
- 精准医疗
- 基因编辑联合治疗



siRNA 修饰序列

裸或未修饰siRNA存在的问题

- ❑ **易降解**：大多数裸或未修饰的siRNA的半衰期在5-10分钟之间，同时未修饰siRNA易被内源性酶降解
- ❑ **易被肾脏清除**：siRNA的长度为7-8 nm，直径为2-3 nm。通常尺寸小于8 nm的分子很容易被肾脏系统过滤。因此未修饰或裸siRNA极易被肾脏清除。研究显示，通过连接配体、掺入较大颗粒或与血浆蛋白结合来增加其分子量可有效避免siRNA被肾脏清除
- ❑ **易脱靶**：裸或未修饰siRNA存在脱靶现象，导致意外后果。化学修饰的siRNA，例如先导siRNA链的2'-O-甲基化，可以减少miRNA样脱靶效应以及免疫刺激活性，且不会失去对靶基因的沉默效果




常见siRNA 修饰介绍

1. **2'-O-甲基 (2'-OMe)**: 增强siRNA的稳定性, 阻止核酸酶的降解, 减少免疫原性, 并增加与靶mRNA的亲合力。
2. **2'-甲氧基乙基 (2'-MOE)**: 与2'-OMe类似, 但显示出更高的结合亲和力, 增加 ΔT_m 值, 从而增强siRNA的抗核酸酶能力。
3. **2'-脱氧-2'-氟 (2'-F)**: 通过电子密度高的氟原子, 促使siRNA更容易采取C3'-内构象, 提高与靶mRNA的结合亲和力。
4. **锁核酸 (LNA)**: 通过在2'位置引入桥接结构, 增强碱基配对的亲和力, 提高siRNA的稳定性和特异性。
5. **非锁定核酸 (UNA)**: 增加siRNA的灵活性和热稳定性, 通过化学不对称性促进导向链的RISC装载。
6. **甘油核酸 (GNA)**: 热稳定性较低的核苷酸, 可用于减少非靶向效应, 如通过包含在siRNA导向链的种子区域来减少肝脏毒性。
7. **磷酸化修饰 (Phosphonate modification)**: 如磷硫酯 (PS) 链接, 提高siRNA对核酸酶的抵抗力, 增加与血浆蛋白的结合, 可能延长循环时间。
8. **5'-(E)-乙烯基磷酸酯 (5'-(E)-VP)**: 在5'端修饰, 增强siRNA的稳定性和RISC装载能力, 提高体内活性。
9. **N-乙基哌啶三唑修饰的腺苷类似物**: 通过Hoogsteen或Watson-Crick面定位, 减少siRNA的免疫原性。
10. **6'-苯基吡咯胞嘧啶 (PhpC)**: 作为胞嘧啶的模拟物, 具有优异的碱基配对保真度、热稳定性, 并且具有高荧光性, 有助于siRNA的检测和细胞内追踪。
11. **2,4-二氟甲基核糖核苷 (rF)**: 在siRNA中内部尿苷的替换, 与腺苷的配对相对不稳定, 有助于减少siRNA的非特异性活性。
12. **5-硝基吡咯**: 在siRNA的乘客链上进行修饰, 可以减少乘客链的活性, 而不影响导向链的效果, 从而减少非靶向效应。

siRNA 沉默效率预估

siRNA与mRNA结合过程



任务目标: siRNA对目标mRNA的沉默效率预测

dsRNA在Dicer酶的作用下, 被切割成短链, 并会在5'端与3'端留下2nt的overhang碱基。


切割后的短链参与形成RNA诱导的沉默复合体(RISC)。

sense-seq与antisense-seq分离, sense-seq会被降解。

antisense-seq 与 mRNA按碱基互补配对原则在靶点位置进行结合, 使得mRNA被切割。



siRNA 模型的信息模型






siRNA 模型的结合特征构建

结合特征构建

结构与能量计算


5' end	-0.9
3' end	-2.1
Sec.dG	2.1
GC stretch	1
Whole ΔG	-24.6
%GC	15.8

方案1:
RNA.fold_comfound()函数
计算siRNA与mRNA的
结合能



方案2:
直接计算mRNA的二级
结构

结合区域计算



方案1: 将mRNA进行多段的切割, 进行动态规划算法的字符串匹配, 避免超时问题

mRNA的模板链


方案2: 将每个位置的碱基使用2bit进行编码, 通过Hamming距离计算最佳字符串匹配位置

mRNA的模板链



大规模siRNA修饰序列数据构建方法

基于公开文献构建 **OCR + LLM校验 + 人工校验** 数据处理流水线
行业内规模最大的修饰siRNA数据库





大规模siRNA修饰序列数据库


标准化修饰缩写

Abbreviation	Chemical Name	Simplified Nucleotide(s)	Nucleotide(s)
(A2p)	adenosine-2'-phosphate	adenosine2phosphate	adenosine-2'-phosphate

标准化数据入库

表头	说明
id	数据记录的唯一标识符，用于唯一标识每条记录
show_id	显示用的标识符，用于前端显示
from source	数据来源，标识数据从何处获取
job_id	任务标识符，用于标识每次数据抓取或处理任务
export_time	数据导出时间，记录数据导出的具体时间
application_id	专利申请号，是指专利在申请过程中获得的唯一标识符
patent_id	专利号，是指专利正式批准后获得的唯一标识符
priority_date	
application_date	
publication_date	
batch_id	批次标识符，用于标识一次数据抓取或处理的批次
batch_header	批次标题，是对批次的简要描述和基本信息
gene_target_seq_id	目标基因序列ID，记录靶向基因的DNA或RNA序列ID
gene_target_symbol_name	目标基因名称，记录siRNA靶向的基因名称
gene_target_ncbi_id	NCBI RefSeq ID，记录目标基因在NCBI RefSeq数据库中的ID
gene_target_ensembl_id	Ensembl Gene ID，记录目标基因在Ensembl数据库中的ID
gene_target_species	目标基因来源物种，记录靶向基因的来源物种
gene_target_seq	目标基因序列，记录靶向基因的DNA或RNA序列
range	siRNA靶向的gene_target区域
siRNA_duplex_id	siRNA双链标识符，用于唯一标识siRNA序列
siRNA_sense_name	
siRNA_antisense_name	
siRNA_sense_seq_id	siRNA正义链序列ID，记录siRNA正义链的核苷酸序列ID
siRNA_antisense_seq_id	siRNA反义链序列ID，记录siRNA反义链的核苷酸序列ID
siRNA_sense_seq	siRNA正义链序列，记录siRNA正义链的核苷酸序列
siRNA_antisense_seq	siRNA反义链序列，记录siRNA反义链的核苷酸序列
modified_siRNA_sense_seq_id	修饰的siRNA正义链序列ID，记录修饰的siRNA正义链的核苷酸序列ID
modified_siRNA_antisense_seq_id	修饰的siRNA反义链序列ID，记录修饰的siRNA反义链的核苷酸序列ID
modified_siRNA_sense_seq	修饰的siRNA正义链序列，记录修饰的siRNA正义链的核苷酸序列
modified_siRNA_antisense_seq	修饰的siRNA反义链序列，记录修饰的siRNA反义链的核苷酸序列
experiment_type	实验类型，记录实验的具体类型
effectiveness	siRNA有效性，记录siRNA在实验中抑制目标基因的效果
off_target_effect	siRNA脱靶效应，记录siRNA对非靶基因的影响或副作用
delivery_method	siRNA传递方法，记录将siRNA引入细胞或生物体的方法
cell_line_donor	细胞系供体，记录使用的细胞系供体信息
animal	体内实验会使用相应动物，没有cell-line
experimental_condition	实验条件，记录siRNA实验的具体条件
% mRNA Remaining	实验中测量到的目标mRNA相对于未处理细胞所剩余的百分比
stdev	标准偏差

RNA 序列基础模型



RNAErnie



(Nature Machine Intelligence 2024)

1. Motif-aware Pretraining: 通过在预训练阶段引入RNA基序作为生物学先验知识，并在基础/子序列级别上应用多级掩码策略，增强了模型对RNA序列的表示能力。1.05亿参数量，基于2300万ncRNA序列训练。

2. Type-guided Fine-tuning: 针对预训练阶段未见过的RNA序列的分布外任务，RNAErnie提出了一种类型引导的微调策略，首先预测可能的RNA类型，然后将预测的类型作为辅助信息附加到序列尾部，以事后方式细化特征嵌入。

RNA 序列基础模型

RiNALMo (arXiv 2024)



Visualization of different RNAs given pre-trained features

1.Large-scale Pretraining : 基于Transformer结构训练，为目前规模最大的RNA序列基础模型。6.5亿参数量，基于3600万ncRNA序列训练。

2.Advanced Transformer: 增加旋转位置嵌入 (RoPE)、SwiGLU激活函数和FlashAttention-2等复杂结构特征优化Transformer训练效率与性能。