



科学研究的人工智能方法学

复旦大学人工智能创新与产业研究院研究员
徐盈辉

未来25年，这125个问题将让科学家“大伤脑筋”

这125个问题，其中涉及生命科学的问题占46%，关系宇宙和地球的问题占16%，与物质科学相关的问题占14%以上，认知科学问题占9%。其余问题分别涉及数学与计算机科学、政治与经济、能源、环境和人口等。

一场正在发生的科研范式变革



《 Science 》刊登麻省理工
AI药物逆合成设计论文，AI合
成了**15个**药物分子

2019.3


利物浦大学使用AI发现**4种**可
传导锂的新固态材料，可提
供更长续航能力

2021.5

Deepmind宣布开放包括多
个动物、植物的**2亿**个蛋白质
结构的预测结果



2022.7

Principles of physics-informed AI




Observation bias

(a) FlagDynamic




风速的平移对称性

(b) DeformingPlate




金属板材质的对称性

(c) CylinderFlow



水流绕柱具有左右对称性


(d) Airfoil




翼型结构的对称性

观测偏差可能导致模型在数据覆盖不足的场景中表现不佳。数据驱动模型依赖于观测数据的质量和多样性，当数据来源有限时，模型往往无法泛化到数据集中未包含的条件或变化。


inductive bias



基于分子结构中的节点（原子）和边（键）的连接方式带来的归纳偏差



节点的层次关系带来的归纳偏差




模型假设信息在有序层级间流动，不会形成循环

learning bias


Example: $u_t + uu_x - (0.01/\pi)u_{xx} = 0, \quad x \in [-1, 1], \quad t \in [0, 1],$
 1D Burgers equation $u(0, x) = -\sin(\pi x),$
 $u(t, -1) = u(t, 1) = 0.$

$$\mathcal{L}(\theta) = \lambda_u \mathcal{L}_u(\theta) + \lambda_r \mathcal{L}_r(\theta)$$




```

1 import jax.numpy as np
2 from jax import grad
3
4 def net_u(params, x, t):
5     inputs = np.stack([x, t])
6     u = self.net_apply(params, inputs)
7     return u[0]
8
9 def net_r(params, x, t):
10     # Compute derivatives
11     u = net_u(params, x, t)
12     u_t = grad(net_u, 2)(params, x, t)
13     u_x = grad(net_u, 1)(params, x, t)
14     u_xx = grad(grad(net_u, 1), 1)(params, x, t)
15     # Compute residual
16     res = u_t + u*u_x - (0.01/np.pi)*u_xx
17     return res
  
```



Predicting 3D protein structure



等变性 (Equivariance)


残基之间的几何关系

多序列比对 (MSA) 的引入


能量最小化的隐含约束

*Physics-guided AI: Equivariance to roto-translations in 3D (SE(3) group symmetry)

Learning velocity and pressure fields from flow visualizations



Automatic design space exploration



- Parametrized multi-physics problem (fluid dynamics + heat transfer).
- Automatic design space exploration for optimizing heat sinks.
- Orders of magnitude speed-up compared to commercial electronics cooling simulation software.



物理信息神经网络 (PINNs)

物理信息神经网络是一种将物理方程作为约束条件引入神经网络的技术。通过自动微分计算神经网络的输出导数，从而在损失函数中引入偏微分方程 (PDE) 残差项，使得网络的预测结果满足物理方程的约束。

Physics Informed Machine Learning (PINN)

守恒定律：系统中的能量、动量等守恒定律。

对称性：系统可能具有的对称性质。

降阶模型：简化的物理模型，能够在不失真或近似的情况下降低系统复杂性。

• **强制或发现物理信息：**将物理知识融入机器学习模型。

• **软约束与硬约束：**

- 软约束：将物理规律以惩罚项的形式加入损失函数。
- 硬约束：直接将物理规律嵌入模型结构中，使其严格满足物理条件。

定义问题：明确需要解决的任务。

数据整理：收集并处理数据。

选择模型架构：决定使用的模型结构。

损失函数：定义损失函数，评估模型预测的误差。

优化：通过优化算法训练模型，使损失最小化。

更高的准确性、泛化性和可信度。
减少数据需求。
从测量数据中发现新的物理规律。



基础物理量

1. **力和动量**：力是动量的变化率，表达为 $F = \frac{dp}{dt}$ 。
2. **动量和质量**：动量是质量和速度的乘积 $p = mv$ 。
3. **能量和质量**：动能与质量和速度的平方成正比 $K = \frac{1}{2}mv^2$ ，势能与质量和位置成正比（例如重力势能 $U = mgh$ ）。
4. **位移和速度**：速度是位移的变化率 $v = \frac{ds}{dt}$ ，而加速度是速度的变化率。
5. **时间**：时间是导数中的变量，用于描述物体的运动和状态变化。
6. **空间位置和位移**：位移描述了空间位置的变化。
7. **密度和质量**：密度是单位体积的质量，用于描述物质在空间中的分布。
8. **质量的作用**：质量是惯性、动量和能量的核心，与力、加速度、动能、势能都紧密相关。



Merits of physics informed AI

物理信息引导的AI可以将不完整的数学模型与不完美的数据结合起来，弥补各自的不足

物理信息的引入增强了模型在小样本数据集上的泛化能力。

高维问题是许多复杂物理系统中的常见难题。PINN 通过物理约束和先验知识，可以有效处理高维函数或算子的逼近问题，降低计算复杂度。

传统深度学习模型往往是“黑箱”系统，缺乏解释性。而PINN 通过引入物理知识，可以增强模型的可解释性，使得模型的预测结果更具物理意义。



Physics-Based & data driven based AI models

- Physics Rules and Equations


连续性方程、
动量守恒方程
能量守恒方程

$$\begin{aligned}\frac{\partial \rho}{\partial t} &= -\nabla \cdot (\rho \mathbf{u}) \\ \frac{\partial \rho \mathbf{u}}{\partial t} &= -\nabla \cdot \left(\frac{1}{\rho} (\rho \mathbf{u}) \otimes (\rho \mathbf{u}) + p \mathbf{I} \right) + \rho \mathbf{g} \\ \frac{\partial E}{\partial t} &= -\nabla \cdot \left(\frac{1}{\rho} (E + p)(\rho \mathbf{u}) \right) + \mathbf{u} \cdot \rho \mathbf{g}\end{aligned}$$

$$\mathbf{H}\Psi = E\Psi$$

Contain knowledge gaps in describing certain processes (turbulence, groundwater flow)

- Computational Models of Dynamical Systems




基于物理的模型的局限性

大量的参数或状态变量：

复杂的物理模型通常包含大量参数，这些参数需要通过实验或数值模拟来确定，增加了模型的复杂性和计算成本。

不完整或缺失的物理/过程知识：

在某些领域，现有的物理知识不足以精确描述系统行为（例如湍流或地下水流），导致模型在实际应用中的表现受限。



Take full advantage of data science methods without ignoring the treasure of accumulated knowledge in scientific “theories”

Require large number of representative samples

物理信息融合的人工智能所关心的核心问题

指导AI模型学习科学一致的解

物理知识可以作为约束或先验信息，帮助AI模型在训练过程中找到符合科学规律的解答。这种科学一致性可以确保模型的预测结果符合实际的物理规律，避免出现违反科学常识的情况。


在训练数据有限的情况下，保证模型的泛化能力

通过物理信息的引导，即使在数据不足的情况下，模型仍然可以利用物理规律进行泛化。这种方式下，模型不再完全依赖数据驱动，而是能够通过物理约束来弥补数据的不足，从而提升在新场景下的表现能力

泛化误差： 训练误差 + 复杂性 + 科学不一致性



物理信息融合的人工智能研究方向



物理帮助人工智能

物理引导的设计

响应函数的选择

模型架构设计

物理引导的学习

使用损失函数、约束、先验知识、训练标签

物理引导的优化

后处理

剪枝

人工智能推动物理学发展

从数据中发现科学定律

符号回归、自动编码器



物理模型参数的推断

模型校准、反演建模、数据同化

混合物理-机器学习建模

残差建模、使用机器学习增强系统组件、预训练

人工智能加速科学计算



- *Supervised*: the data is produced by a physical system (real or simulated), but no further interaction exists. This is the classic machine learning approach.
- *Loss-terms*: the physical dynamics (or parts thereof) are encoded in the loss function, typically in the form of differentiable operations. The learning process can repeatedly evaluate the loss, and usually receives gradients from a PDE-based formulation. These soft constraints sometimes also go under the name “physics-informed” training.
- *Interleaved*: the full physical simulation is interleaved and combined with an output from a deep neural network; this requires a fully differentiable simulator and represents the tightest coupling between the physical system and the learning process. Interleaved differentiable physics approaches are especially important for temporal evolutions, where they can yield an estimate of the future behavior of the dynamics.


Physics-informed Model Design

- Choice of Model Architecture Governed by Scientific Knowledge

Encoding invariances/symmetries in ANN architecture


- Rotational/translational invariance in ANN structure
- Symmetries linked to conservation of physical quantities

Kondor et al. arXiv 2018; Ling et al. *JFM*, 2016



Hard-wiring physics in LSTM connections


- Application in Lake Temperature Modeling
- Provides better uncertainty quantification when used with MC Dropout, while ensuring physical consistency



Daw et al. *SDM* 2020

Using Physical Intermediates at Hidden Layers of NN

- Application in Fluid Dynamics: Drag Force Prediction



Muralidhar et al. *SDM* 2020

- ML results on test set can be post-processed (pruned/improved) using domain theories


Example in Material Science: Discovery of novel materials


Hautier et al. 2010, Fischer et al. 2006, Curtarolo et al. 2013

- Computationally expensive (DFT) methods used for checking material properties
- Prune discovered materials using theory-based models
- **Discovery of hundred new ternary oxides**


Post-processing
using physics-
based models

Hautier et al. 2010





Physics informed Machine Learning components




表示模型 (Representation Model) : 近似微分方程 (ODE/PDE) 解的模型, 表示为 $\mathcal{M}(\theta, x)$, 其中 x 是输入, θ 是可学习的参数。通过该模型可以得到一个解的近似值 u , 用于与真实解进行比较

控制方程 (Governing Equations) : 该模块包含了物理定律、边界条件 (BCs) 以及数据等已知信息。表示模型输出的近似解 u 会通过求导等计算产生残差 (Residuals), 即近似解与真实物理规律之间的不匹配。残差的计算考虑了已知的物理约束, 以确保模型在训练时遵守物理规律

优化过程 (Optimization Process) : 定义一个多目标优化问题, 以最小化残差的损失函数, 从而更新模型的参数 θ 。优化器根据残差信息不断调整表示模型的参数, 使得模型解能够更好地符合物理定律和边界条件。

Representation Model Enhancements





输入变换

对输入做变换，神经网络能够更容易地学习到复杂特征和规律，特别是在周期性、高频、多尺度等场景下。

- **精确周期性边界条件 (Exact Periodic BCs)**: 使用正弦和余弦函数 (如 $\sin(\omega x)$ 、 $\cos(\omega x)$) 来构造周期性特征。
- **特征扩展 (Feature Expansions)**: 扩展输入特征空间，比如使用指数函数、正弦函数、对数等不同的特征表示。
- **傅里叶特征 (Fourier Features)**: 通过使用傅里叶特征 (如 $\cos(Bx)$ 、 $\sin(Bx)$) 来丰富模型的频谱内容，能够缓解频谱偏差，提高模型处理复杂边界条件的能力。



残差连接

残差连接 (Residual Connections)

残差连接可以提高模型的性能和精度，尤其是在需要计算高阶导数的情况下。残差连接能够有效地帮助模型学习复杂的特征，并增强网络对PDE的拟合能力。

感知机修改 (Perceptron Modifications)

- **权重归一化 (Weight Normalization)**: 通过权重向量的归一化, 使得权重 W 得到稳定的值, 以提升模型的数值稳定性。
- **权重因子化 (Weight Factorization)**: 通过将权重矩阵分解为一个对角矩阵和向量的乘积, 达到更好的参数化效果。
- **自适应激活函数 (Adaptive Activation Functions)**: 通过为每个神经元选择自适应激活函数 (例如, 使用系数 a_i 和不同的激活函数 $\sigma_i(f_i \cdot)$), 提升模型的学习能力。




输出变换


输出变换 (Output Transformations)

输出变换用于施加一些边界条件或复杂的约束，以确保模型的输出满足实际的物理需求：

- **精确的Dirichlet边界条件 (Exact Dirichlet BCs)**: 通过输出变换 $\Gamma(z_L) = \phi(z_L) + g(x)$ 来精确满足Dirichlet边界条件。
- **约束域 (Constrained Domain)**: 输出变换可以确保输出落在特定的域内，例如通过 $\Gamma(z_L) = |z_L|$ 保证输出非负。
- **复杂约束 (Complex Constraints)**: 通过其他复杂的约束 (如 $\Gamma(z_L) = \nabla \times z_L$) 来施加更加特定的物理约束。


Governing Equations






软组织中的位移场重建

a) Reconstructing displacement fields with estimated parameters in soft tissues (Caforio 2024)




c) Transduction-time distributions estimation in cell biology (Jo 2024)




细胞生物学中的转
导时间分布估计

心室内血流矢量的重建

b) Reconstruction of intraventricular vector blood (Ling 2024)




a) Turbulent jet (Cai 2024)




湍流射流是一种典型的复杂流动现象，广泛应用于工程和自然科学中，例如在燃烧器、喷气发动机和河流入海口的流动等场景

b) Flow over an espresso cup
(Cai 2021)





液体表面上方的热空气流动

c) Flow around a swimming fish (Calicchia 2023)



鱼在水中游动时所产生的流体湍流结构

d) Rayleigh-Bernard Convection
(Toscano 2024)



Rayleigh-Bénard对流现象

